

HO CHI MINH UNIVERSITY OF TECHNOLOGY - VIETNAM NATIONAL  
UNIVERSITY HO CHI MINH CITY



Học máy (CO3117)

Báo cáo bài tập lớn

Hệ thống dự đoán chứng khoán

---

Giáo viên: Võ Thanh Hùng

|            |                  |         |
|------------|------------------|---------|
| Sinh viên: | Đỗ Tiến Dũng     | 2210569 |
|            | Trương Bình Minh | 2212088 |
|            | Nguyễn Anh Lâm   | 2211795 |

Thành phố Hồ Chí Minh, 4/2025

## Mục lục

|          |                                                    |          |
|----------|----------------------------------------------------|----------|
| <b>1</b> | <b>Giới thiệu</b>                                  | <b>3</b> |
| <b>2</b> | <b>Cơ sở lý thuyết</b>                             | <b>4</b> |
| 2.1      | Linear Regression . . . . .                        | 4        |
| 2.1.1    | Khái niệm . . . . .                                | 4        |
| 2.1.2    | Mục tiêu của Linear Regression . . . . .           | 4        |
| 2.1.3    | Hàm mất mát . . . . .                              | 4        |
| 2.1.4    | Tối ưu hàm mất mát . . . . .                       | 5        |
| 2.2      | Naive bayes . . . . .                              | 5        |
| 2.2.1    | Khái niệm . . . . .                                | 5        |
| 2.2.2    | Định lý Bayes . . . . .                            | 5        |
| 2.2.3    | Giả định độc lập . . . . .                         | 6        |
| 2.3      | Support Vector Machine . . . . .                   | 6        |
| 2.3.1    | Khái niệm . . . . .                                | 6        |
| 2.3.2    | Máy phân loại tuyến tính . . . . .                 | 6        |
| 2.3.3    | Soft-margin SVM . . . . .                          | 6        |
| 2.3.4    | Dạng đối ngẫu và hàm kernel . . . . .              | 7        |
| 2.3.5    | Ưu điểm và nhược điểm . . . . .                    | 7        |
| 2.3.6    | Ứng dụng . . . . .                                 | 7        |
| 2.4      | K-nearest neighbors (KNN) . . . . .                | 7        |
| 2.4.1    | Khái niệm . . . . .                                | 7        |
| 2.4.2    | Cách hoạt động . . . . .                           | 8        |
| 2.5      | Decision tree . . . . .                            | 8        |
| 2.5.1    | Khái niệm . . . . .                                | 8        |
| 2.5.2    | Các thành phần cơ bản của Decision tree . . . . .  | 8        |
| 2.5.3    | Tiêu chí phân chia (Splitting Criteria) . . . . .  | 9        |
| 2.5.4    | Các giải thuật thường gặp . . . . .                | 9        |
| 2.5.5    | Ứng dụng . . . . .                                 | 11       |
| 2.6      | Random forest . . . . .                            | 11       |
| 2.6.1    | Khái niệm . . . . .                                | 11       |
| 2.6.2    | Cách hoạt động . . . . .                           | 11       |
| 2.6.3    | Các tham số quan trọng . . . . .                   | 12       |
| 2.6.4    | Cách Random Forest khắc phục overfitting . . . . . | 12       |
| 2.6.5    | Đánh giá mô hình . . . . .                         | 12       |
| 2.7      | AdaBoost . . . . .                                 | 12       |
| 2.7.1    | Khái niệm . . . . .                                | 12       |
| 2.7.2    | Nguyên lý hoạt động . . . . .                      | 12       |
| 2.7.3    | Ý tưởng chính . . . . .                            | 13       |
| 2.7.4    | Cách hoạt động . . . . .                           | 13       |
| 2.8      | XGBoost . . . . .                                  | 14       |
| 2.8.1    | Khái niệm . . . . .                                | 14       |
| 2.8.2    | Thuật toán Gradient Boosting . . . . .             | 14       |
| 2.8.3    | Hàm mục tiêu và tối ưu . . . . .                   | 14       |
| 2.8.4    | Xây dựng cây (Tree Booster) . . . . .              | 14       |
| 2.8.5    | Các tham số chính . . . . .                        | 15       |
| 2.8.6    | Ưu điểm và nhược điểm . . . . .                    | 15       |
| 2.8.7    | Ứng dụng . . . . .                                 | 15       |



|          |                                               |           |
|----------|-----------------------------------------------|-----------|
| 2.9      | TF-IDF vector . . . . .                       | 15        |
| 2.9.1    | Khái niệm . . . . .                           | 15        |
| 2.9.2    | Các thành phần của TF-IDF . . . . .           | 16        |
| 2.9.3    | Kết luận . . . . .                            | 16        |
| 2.10     | PhoBERT . . . . .                             | 17        |
| 2.10.1   | BERT . . . . .                                | 17        |
| 2.10.2   | RoBERTa . . . . .                             | 17        |
| 2.10.3   | PhoBERT . . . . .                             | 18        |
| <b>3</b> | <b>Thí nghiệm</b>                             | <b>19</b> |
| 3.1      | Dữ liệu . . . . .                             | 19        |
| 3.1.1    | Dữ liệu về giá của các cổ phiếu . . . . .     | 19        |
| 3.1.2    | Dữ liệu về tin tức của các cổ phiếu . . . . . | 20        |
| 3.1.3    | Tiền sử lý dữ liệu . . . . .                  | 20        |
| 3.2      | Dataset . . . . .                             | 21        |
| 3.2.1    | Dữ liệu giá chứng khoán . . . . .             | 21        |
| 3.2.2    | Dữ liệu tin tức hàng ngày . . . . .           | 22        |
| 3.3      | Linear Regression - Baseline . . . . .        | 23        |
| 3.4      | Naive bayes . . . . .                         | 26        |
| 3.4.1    | TF-IDF . . . . .                              | 26        |
| 3.4.2    | PhoBert . . . . .                             | 27        |
| 3.5      | Support vector machine . . . . .              | 28        |
| 3.5.1    | TF-IDF vector . . . . .                       | 29        |
| 3.5.2    | PhoBert . . . . .                             | 29        |
| 3.6      | K-nearest neighbors . . . . .                 | 29        |
| 3.6.1    | TF-IDF vector . . . . .                       | 30        |
| 3.6.2    | PhoBert . . . . .                             | 31        |
| 3.7      | Decision tree . . . . .                       | 32        |
| 3.7.1    | TF-IDF vector . . . . .                       | 32        |
| 3.7.2    | PhoBert . . . . .                             | 34        |
| 3.8      | Random forest . . . . .                       | 35        |
| 3.8.1    | TF-IDF vector . . . . .                       | 35        |
| 3.8.2    | PhoBert . . . . .                             | 37        |
| 3.9      | AdaBoost . . . . .                            | 38        |
| 3.9.1    | TF-IDF vector . . . . .                       | 38        |
| 3.9.2    | PhoBert . . . . .                             | 40        |
| 3.10     | XGBoost . . . . .                             | 41        |
| 3.10.1   | TF-IDF vector . . . . .                       | 41        |
| 3.10.2   | PhoBert . . . . .                             | 43        |
| 3.11     | LightGBM . . . . .                            | 44        |
| 3.11.1   | TF-IDF vector . . . . .                       | 44        |
| 3.11.2   | PhoBert . . . . .                             | 46        |
| 3.12     | Tổng hợp và nhận xét . . . . .                | 48        |
| <b>4</b> | <b>Kết luận</b>                               | <b>49</b> |



## 1 Giới thiệu

Trong sự bùng nổ của trí tuệ nhân tạo và học máy (artificial intelligence and machine learning), việc ứng dụng trí tuệ nhân tạo và học máy vào các lĩnh vực kinh tế - tài chính đang dần trở thành xu thế. Trong đó, việc dự đoán xu hướng của thị trường chứng khoán là một bài toán khó nhưng đầy tiềm năng. Với mục tiêu khai thác thông tin từ dữ liệu giá cổ phiếu và tin tức tài chính để đưa ra dự đoán về xu hướng biến động trong tương lai, nhóm chúng em đã thực hiện đề tài “Hệ thống dự đoán chứng khoán” trong khuôn khổ môn học Học máy (CO3117).

Thông qua việc áp dụng các thuật toán học máy cổ điển và hiện đại kết hợp cùng với việc xử lý và khai thác dữ liệu tin tức bằng TF-IDF và PhoBERT, nhóm kỳ vọng xây dựng được một hệ thống có khả năng hỗ trợ các nhà đầu tư trong việc ra quyết định.

## 2 Cơ sở lý thuyết

### 2.1 Linear Regression

#### 2.1.1 Khái niệm

Linear Regression là một thuật toán dự đoán giá trị đầu ra (biến phụ thuộc  $y$ ) dựa trên một hoặc nhiều biến đầu vào (biến độc lập  $x$ ), giả định mối quan hệ giữa  $x$  và  $y$  là tuyến tính.

**Công thức tổng quát:**

– Đơn biến:

$$\hat{y} = w_0 + w_1x$$

– Đa biến:

$$\hat{y} = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n$$

Hoặc viết dưới dạng vector:

$$\hat{y} = \bar{x}W$$

Với:

- +  $W = [w_0, w_1, \dots]^T$ : ma trận hệ số
- +  $\bar{x} = [1, x_1, x_2, \dots]$ : vector dữ liệu đầu vào

#### 2.1.2 Mục tiêu của Linear Regression

Tìm các hệ số  $w_0, w_1, \dots, w_n$  sao cho mô hình dự đoán gần đúng nhất với dữ liệu thực tế.

#### 2.1.3 Hàm mất mát

Hàm mất mát phổ biến nhất dùng trong Linear Regression là Mean Squared Error (MSE):

$$L(w) = \frac{1}{2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \frac{1}{2} \sum_{i=1}^n (y_i - \bar{x}_i W)^2$$

Với:

- $y_i$ : giá trị thực tế
- $\hat{y}_i$ : giá trị dự đoán
- $\bar{x}_i$ : vector đặc trưng của mẫu thứ  $i$

#### 2.1.4 Tối ưu hàm mất mát

- a. Đạo hàm và giải phương trình

Đạo hàm theo  $W$  của hàm mất mát là:

$$\frac{\partial L(W)}{\partial W} = \bar{X}^T (\bar{X}W - y)$$

Nghiệm tối ưu của bài toán Linear Regression có dạng:

$$W = (\bar{X}^T \bar{X})^{-1} \bar{X}^T y$$

- b. Gradient Descent:

$$W := W - \alpha \frac{\partial L(W)}{\partial W}$$

Với:

- +  $\alpha$ : learning rate
- +  $\frac{\partial L(W)}{\partial W}$ : đạo hàm của hàm mất mát

## 2.2 Naive bayes

### 2.2.1 Khái niệm

Naive Bayes là một nhóm các thuật toán phân loại dựa trên Định lý Bayes, với giả định độc lập có điều kiện (naive assumption) giữa các đặc trưng:

- Giả định rằng tất cả các đặc trưng (features) đều độc lập với nhau, cho trước nhãn (label).
- Điều này hiếm khi đúng trong thực tế, nhưng vẫn cho kết quả rất tốt trong nhiều trường hợp.

### 2.2.2 Định lý Bayes

$$P(Y|X) = \frac{P(X|Y) \cdot P(Y)}{P(X)}$$

Với:

- $Y$ : lớp cần dự đoán (label)
- $X = \{x_1, x_2, x_3, \dots, x_n\}$ : các đặc trưng đầu vào
- $P(Y|X)$ : xác suất của lớp  $Y$  khi biết  $X$  (posterior)
- $P(X|Y)$ : xác suất quan sát được  $X$  khi biết  $Y$  (likelihood)
- $P(Y)$ : xác suất tiên nghiệm (prior) của lớp  $Y$
- $P(X)$ : xác suất quan sát được  $X$  (marginal likelihood)

Vì  $P(X)$  giống nhau cho mọi lớp, nên ta chỉ cần so sánh tử số:

$$\hat{Y} = \arg \max_Y P(Y) \cdot \prod_{i=1}^n P(x_i | Y)$$

### 2.2.3 Giả định độc lập

Naive Bayes giả định rằng:

$$P(x_1, x_2, \dots, x_n | Y) = \prod_{i=1}^n P(x_i | Y)$$

Tức là mỗi đặc trưng  $x_i$  độc lập với các đặc trưng khác nếu đã biết nhãn  $Y$ .

## 2.3 Support Vector Machine

### 2.3.1 Khái niệm

- Support Vector Machine (SVM) là một thuật toán phân loại (và hồi quy) trong học máy, tìm siêu phẳng (hyperplane) tối ưu để phân tách các lớp dữ liệu trong không gian đặc trưng.
- Ý tưởng chính: tối đa hoá khoảng cách (margin) giữa siêu phẳng phân tách và các điểm dữ liệu gần nhất (support vectors).
- SVM có thể mở rộng để xử lý dữ liệu không tuyến tính bằng cách dùng hàm kernel để ánh xạ lên không gian cao chiều.

### 2.3.2 Máy phân loại tuyến tính

$$f(\mathbf{x}) = \mathbf{w}^\top \mathbf{x} + b,$$

- Ràng buộc đối với dữ liệu phân lớp nhị phân  $\{(\mathbf{x}_i, y_i)\}_{i=1}^N$ , với  $y_i \in \{-1, +1\}$ :

$$y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1.$$

- Bài toán tối ưu hoá Biên tối đa (Hard-margin SVM):

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad \text{với ràng buộc} \quad y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1, \quad \forall i.$$

### 2.3.3 Soft-margin SVM

- Để xử lý dữ liệu không phân tách tuyệt đối, thêm biến slack  $\xi_i \geq 0$ :

$$y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

- Mục tiêu tối ưu:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^N \xi_i,$$

trong đó  $C > 0$  là tham số điều chỉnh độ phạt vi phạm margin.

### 2.3.4 Dạng đối ngẫu và hàm kernel

- Dạng đối ngẫu (dual form) tối ưu theo nhân tử Lagrange  $\alpha_i$ :

$$\max_{\alpha} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle,$$

với ràng buộc  $0 \leq \alpha_i \leq C$ ,  $\sum_i \alpha_i y_i = 0$ .

- Đưa vào hàm kernel  $K(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle$  để xử lý phi tuyến:

$$f(\mathbf{x}) = \sum_{i=1}^N \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b.$$

- Các kernel phổ biến: tuyến tính, đa thức (polynomial), RBF (Gaussian), sigmoid.

### 2.3.5 Ưu điểm và nhược điểm

- **Ưu điểm:**

- + Hiệu quả với không gian đặc trưng cao chiều.
- + Ít bị overfitting nhờ tối ưu biên lớn nhất và điều chỉnh tham số  $C$ .
- + Linh hoạt với nhiều loại kernel khác nhau.

- **Nhược điểm:**

- + Tính toán chi phí cao khi dữ liệu lớn (thời gian và bộ nhớ tăng theo  $O(N^2)$ ).
- + Cần hiệu chỉnh tham số kernel và  $C$ , có thể tốn kém tính toán.
- + Ít trực quan so với các mô hình cây quyết định.

### 2.3.6 Ứng dụng

- Phân loại văn bản và nhận dạng chữ viết tay.
- Phân loại ảnh và phát hiện đối tượng.
- Bioinformatics: phân loại gen và protein.
- Phân loại tín dụng và phát hiện gian lận.
- Hệ thống chẩn đoán y tế và phân loại bệnh nhân.

## 2.4 K-nearest neighbors (KNN)

### 2.4.1 Khái niệm

KNN là một thuật toán học có giám sát (supervised learning) được sử dụng cho cả phân loại (classification) và hồi quy (regression).

Nguyên lý hoạt động: Khi cần dự đoán đầu ra của một điểm mới, KNN sẽ tìm K điểm dữ liệu gần nhất (láng giềng gần nhất) trong tập huấn luyện và quyết định kết quả dựa vào đa số (classification) hoặc trung bình (regression) của các điểm đó.



### 2.4.2 Cách hoạt động

1. Xác định giá trị của K
2. Tính khoảng cách từ điểm cần dự đoán đến tất cả các điểm trong tập huấn luyện

Một số loại khoảng cách phổ biến:

+ Euclidean Distance:

$$d(p, q) = \sqrt{\sum_{i=1}^n (p_i - q_i)^2}$$

+ Manhattan Distance:

$$d(p, q) = \sum_{i=1}^n |p_i - q_i|$$

3. Chọn K láng giềng gần nhất.
4. Dự đoán kết quả dựa trên bỏ phiếu của K láng giềng gần nhất.

## 2.5 Decision tree

### 2.5.1 Khái niệm

- Một cây quyết định(decision tree) là một đồ thị của các quyết định và các hậu quả có thể của nó (bao gồm rủi ro và hao phí tài nguyên). Cây quyết định được sử dụng để xây dựng một kế hoạch nhằm đạt được mục tiêu mong muốn.
- Trong học máy, decision tree được sử dụng để phân loại (classification) và hồi quy (regression) thông qua việc tách dữ liệu theo các thuộc tính cho trước
- Cây bắt đầu từ nút gốc (root), các nút nội (internal nodes) và kết thúc tại các nút lá (leaf nodes), nơi biểu diễn nhãn lớp hoặc giá trị dự đoán

### 2.5.2 Các thành phần cơ bản của Decision tree

- Nút gốc (root node) đại diện cho tập dữ liệu ban đầu trước khi phân chia
- Nút nội (internal node) thực hiện phép kiểm tra điều kiện trên một thuộc tính
- Nút lá (leaf node) chứa giá trị quyết định hoặc nhãn lớp cuối cùng

### 2.5.3 Tiêu chí phân chia (Splitting Criteria)

- Entropy và Information Gain
  - + Entropy đo độ hỗn loạn của tập dữ liệu và được tính theo công thức  $H(S) = -\sum_i p_i \log_2 p_i$ .
  - + Information Gain (IG) bằng phần giảm entropy khi tách dữ liệu theo một thuộc tính và được tính bằng  $IG(S, A) = H(S) - \sum_{v \in \text{Values}(A)} \frac{|S_v|}{|S|} H(S_v)$ .
- Gini Index
  - + Gini index là một phép đo độ không tinh khiết được định nghĩa là:  $Gini(S) = 1 - \sum_i p_i^2$ .
  - + Giá trị Gini càng nhỏ nghĩa là tập con càng “tinh khiết” và được ưu tiên chọn làm phân chia tại nút
- Các tiêu chí khác
  - + Một số tiêu chí khác như chi-square test, Gain Ratio, giảm phương sai (variance reduction) cũng được sử dụng tùy thuộc bài toán phân loại hoặc hồi quy

### 2.5.4 Các giải thuật thường gặp

- ID3 (Iterative Dichotomiser 3): sử dụng entropy và information gain để chọn thuộc tính tách dữ liệu tại mỗi bước
  - + Kiểm tra điều kiện dừng:
    - \* Nếu tất cả các mẫu trong tập dữ liệu đều thuộc cùng một lớp, tạo nút lá với nhãn lớp đó.
    - \* Nếu không còn thuộc tính nào để chia, tạo nút lá với nhãn lớp chiếm đa số.
  - + Chọn thuộc tính tốt nhất:
    - \* Tính độ sai phân (entropy) của tập S và entropy của S khi chia theo mỗi thuộc tính A
    - \* Tính Information Gain và chọn thuộc tính có IG lớn nhất.
  - + Tách và đệ quy:
    - \* Chia S thành các tập con  $S_v$  theo từng giá trị v của thuộc tính A.
    - \* Với mỗi tập con, gọi đệ quy để xây tiếp cây con.
  - + Hoàn thiện
    - \* Sau cùng, ta thu được một cây phân loại với nút nội tại là các phép kiểm tra thuộc tính và nút lá là nhãn lớp.
- C4.5: Là phiên bản cải tiến của ID3, sử dụng Gain Ratio để khắc phục thiên lệch của Information Gain đối với thuộc tính nhiều giá trị
  - + Gain Ratio thay cho Information Gain

$$\text{GainRatio}(S, A) = \frac{IG(S, A)}{\text{SplitInfo}(S, A)},$$

trong đó

$$\text{SplitInfo}(S, A) = - \sum_v \frac{|S_v|}{|S|} \log_2 \frac{|S_v|}{|S|}.$$

Điều này giảm thiểu xu hướng chọn thuộc tính “nhiều nhánh”.

+ Xử lý thuộc tính liên tục

- \* Tính ngưỡng tách  $\theta$  sao cho max hóa Gain Ratio, rồi coi mỗi thuộc tính liên tục như hai giá trị

+ Xử lý giá trị thiếu

- \* Khi một mẫu thiếu giá trị A, phân phối mẫu đó tỉ lệ theo tập con khả thi khi tính các tiêu chí.

+ cắt tỉa(Pruning)

- \* Dùng error-based pruning: so sánh sai số trên tập kiểm định trước và sau khi loại bỏ một nhánh; loại bỏ nếu không làm tăng sai số.

+ Đặc điểm

- \* Cho ra cây có thể không nhị phân (mỗi thuộc tính chia nhiều nhánh).
- \* Ổn định hơn ID3, ít bị overfit hơn nhờ Gain Ratio và pruning tích hợp.

+ Ưu điểm và Nhược điểm

- \* Ưu điểm
  - Dễ hiểu, trực quan, kết quả dưới dạng cây dễ trình bày cho người dùng.
  - Tính toán đơn giản, nhanh với tập dữ liệu không quá lớn.
- \* Nhược điểm
  - Thường thiên lệch về các thuộc tính có nhiều giá trị.
  - Dễ overfit nếu không giới hạn độ sâu hoặc kích cỡ nút.
  - Không xử lý tốt thuộc tính liên tục (cần chia ngưỡng thủ công).

– CART (Classification And Regression Tree): Sử dụng Gini index cho bài toán phân loại và độ giảm phương sai (variance reduction) cho bài toán hồi quy.

+ Cây nhị phân:

- \* Mỗi nút chỉ chia thành 2 nhánh bằng cách chọn cặp  $(A, \theta)$  tối ưu.

+ **Tiêu chí tách**

- \* *Phân loại*: dùng Gini index

$$\text{Gini}(S) = 1 - \sum_i p_i^2,$$

chọn  $(A, \theta)$  sao cho tổng Gini cho hai nhánh nhỏ nhất.

- \* *Hồi quy*: dùng variance reduction

$$\Delta \text{Var} = \text{Var}(S) - \left( \frac{|S_L|}{|S|} \text{Var}(S_L) + \frac{|S_R|}{|S|} \text{Var}(S_R) \right).$$

+ **Cost-Complexity Pruning**

- \* Xây dựng cây tối đa trước, sau đó với mỗi giá trị  $\alpha$  (độ phạt độ phức tạp), tìm cây con  $T_\alpha$  tối ưu sao cho

$$C_\alpha(T) = \sum_{t \in \text{leaves}(T)} R(t) + \alpha |\text{leaves}(T)|$$

nhỏ nhất (với  $R(t)$  là sai số tại nút lá  $t$ ).

+ Ưu điểm và Nhược điểm

- \* Ưu điểm
  - Cây nhị phân đơn giản, dễ triển khai.
  - Đồng nhất khung cho classification và regression.
- \* Nhược điểm
  - Cần tinh chỉnh tham số  $\alpha$  để pruning.
  - Vẫn có thể overfit nếu  $\alpha$  quá nhỏ hoặc dữ liệu nhiều nhiễu.

### 2.5.5 Ứng dụng

Decision tree, với cấu trúc trực quan và khả năng diễn giải cao, đã trở thành công cụ nền tảng trong học máy và trí tuệ nhân tạo, được áp dụng rộng rãi across nhiều lĩnh vực. Một số ứng dụng như:

- Chẩn đoán y tế và phân tầng nguy cơ bệnh nhân: Hỗ trợ xác định mức độ nghiêm trọng của bệnh (ví dụ COVID-19), tiên lượng kết quả và đề xuất phác đồ điều trị
- Phát hiện gian lận tài chính (Fraud Detection): Nhận diện giao dịch thẻ tín dụng khả nghi và hành vi gian lận dựa trên mẫu lịch sử giao dịch
- Bảo trì dự báo (Predictive Maintenance): Dự đoán sự cố máy móc, thiết bị công nghiệp trước khi xảy ra hỏng hóc dựa trên dữ liệu cảm biến và lịch sử vận hành

## 2.6 Random forest

### 2.6.1 Khái niệm

Random Forest là một thuật toán học có giám sát (supervised learning) dùng cho cả phân loại (classification) và hồi quy (regression).

Random Forest là một ensemble method (phương pháp tổng hợp), kết hợp nhiều Cây quyết định (Decision Trees) để tạo ra một mô hình mạnh hơn, chính xác hơn và giảm overfitting.

### 2.6.2 Cách hoạt động

1. Tạo nhiều cây quyết định (decision trees) độc lập.
2. Mỗi cây huấn luyện trên một tập dữ liệu con được chọn ngẫu nhiên từ tập huấn luyện ban đầu (bootstrapping).
3. Ở mỗi node, chọn một tập con ngẫu nhiên của các đặc trưng (features) để phân chia tốt nhất  $\rightarrow$  tăng tính ngẫu nhiên và giảm tương quan giữa các cây.
4. Dự đoán bằng vote đa số (với classification) hoặc trung bình (với regression) từ các cây.

### 2.6.3 Các tham số quan trọng

| Tham số           | Giải thích                          |
|-------------------|-------------------------------------|
| n_estimators      | Số lượng cây                        |
| max_features      | Số đặc trưng được xét khi phân chia |
| max_depth         | Chiều sâu tối đa của cây            |
| min_samples_split | Số lượng mẫu tối thiểu để tách      |
| min_samples_leaf  | Số mẫu tối thiểu ở lá               |

### 2.6.4 Cách Random Forest khắc phục overfitting

- Một cây đơn có thể overfit → Random Forest trung bình hóa nhiều cây → giảm phương sai.
- Sự ngẫu nhiên trong dữ liệu đầu vào và feature splitting giúp các cây độc lập hơn.

### 2.6.5 Đánh giá mô hình

- Với classification:
  - + Accuracy / Precision / Recall / F1-score
  - + ROC AUC
- Với regression:
  - + Mean Squared Error (MSE)
  - + Root Mean Squared Error (RMSE)

## 2.7 AdaBoost

### 2.7.1 Khái niệm

AdaBoost (Adaptive Boosting) là một thuật toán Boosting thuộc loại học có giám sát (supervised learning), chủ yếu dùng để phân loại (classification) và đôi khi cũng dùng cho hồi quy (regression).

Mục tiêu chính: Kết hợp nhiều mô hình yếu (weak learners) thành một mô hình mạnh (strong learner) bằng cách huấn luyện chúng tuần tự, mỗi mô hình sau sẽ tập trung nhiều hơn vào các mẫu bị sai của mô hình trước.

### 2.7.2 Nguyên lý hoạt động

- Boosting không học tất cả các mô hình song song như Bagging (vd: Random Forest) mà học tuần tự từng mô hình một.
- Mỗi mô hình mới sẽ cố sửa lỗi mà mô hình trước mắc phải.
- Cuối cùng, kết quả của tất cả các mô hình yếu sẽ được kết hợp có trọng số để tạo thành kết quả cuối.

### 2.7.3 Ý tưởng chính

- AdaBoost bắt đầu bằng việc gán trọng số bằng nhau cho tất cả mẫu trong tập huấn luyện.
- Sau mỗi lần huấn luyện mô hình yếu (thường là Decision Stump – cây độ sâu 1), các mẫu được phân loại sai sẽ được tăng trọng số, các mẫu phân loại đúng sẽ được giảm trọng số.
- Mô hình kế tiếp sẽ tập trung nhiều hơn vào các mẫu bị sai, từ đó dần cải thiện tổng thể.

### 2.7.4 Cách hoạt động

1. Khởi tạo trọng số quan sát  $w_i = \frac{1}{N}$
2. Lặp lại quá trình huấn luyện chuỗi mô hình ở mỗi bước  $b, b = 1, 2, 3, \dots, B$  gồm các bước con:
  - a. Khớp mô hình  $\hat{f}^b$  cho tập huấn luyện sử dụng trọng số  $w_i$  cho mỗi quan sát  $(x_i, y_i)$
  - b. Tính sai số huấn luyện:

$$r_b = \frac{\sum_{i=1}^n w_i \mathbb{I}(y_i \neq \hat{f}^b(\mathbf{x}_i))}{\sum_{i=1}^n w_i}$$

$\mathbb{I}(y_i \neq \hat{f}^b(\mathbf{x}_i))$  là những quan sát bị dự báo sai ở mô hình thứ  $b, r_b \in [0, 1]$

- c. Tính trọng số quyết định cho từng mô hình:

$$\alpha_b = \log\left(\frac{1 - r_b}{r_b}\right)$$

- d. Cập nhật trọng số cho từng quan sát:

$$w_i := w_i \exp[\alpha_b \mathbb{I}(y_i \neq \hat{f}^b(\mathbf{x}_i))]$$

Như vậy:

$$w_i := \begin{cases} w_i & \text{if } y_i = \hat{f}^b(\mathbf{x}_i) \\ w_i \exp(\alpha_b) & \text{if } y_i \neq \hat{f}^b(\mathbf{x}_i) \end{cases}$$

Sau khi tính xong các trọng số  $w_i$  thì giá trị của chúng sẽ được chuẩn hoá bằng cách chia cho tổng  $\sum_{i=1}^n w_i$

3. Cập nhật dự báo cuối cùng:

$$\hat{f}(\mathbf{x}) = \text{sign}\left(\sum_{i=1}^p \alpha_i \hat{f}^i(\mathbf{x})\right)$$

## 2.8 XGBoost

### 2.8.1 Khái niệm

- XGBoost (eXtreme Gradient Boosting) là một thư viện tối ưu cho thuật toán Gradient Boosted Trees, được thiết kế để hiệu năng cao và khả năng mở rộng trên dữ liệu lớn.
- XGBoost kết hợp các kỹ thuật regularization, xử lý thiếu giá trị và pruning để giảm overfitting và tăng tính tổng quát của mô hình.

### 2.8.2 Thuật toán Gradient Boosting

- Gradient Boosting xây dựng mô hình theo dạng tổ hợp của  $K$  cây quyết định:

$$\hat{y}_i = \sum_{k=1}^K f_k(\mathbf{x}_i), \quad f_k \in \mathcal{F},$$

với  $\mathcal{F}$  là không gian các cây quyết định.

- Mỗi cây mới được huấn luyện để khớp gradients (residuals) của hàm mất mát tại bước trước.

### 2.8.3 Hàm mục tiêu và tối ưu

$$\mathcal{L}(\phi) = \sum_{i=1}^n \ell(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \sum_{k=1}^t \Omega(f_k),$$

trong đó

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

- $T$ : số lá của cây,  $w_j$ : giá trị tại lá  $j$ ,  $\gamma, \lambda$  là hệ số điều chuẩn.  
Dùng khai triển Taylor bậc hai để xấp xỉ hàm mất mát:

$$\tilde{\mathcal{L}}^{(t)} = \sum_{i=1}^n \left[ g_i f_t(\mathbf{x}_i) + \frac{1}{2} h_i f_t(\mathbf{x}_i)^2 \right] + \Omega(f_t),$$

với  $g_i = \partial_{\hat{y}^{(t-1)}} \ell(y_i, \hat{y}^{(t-1)})$ ,  $h_i = \partial_{\hat{y}^{(t-1)}}^2 \ell(y_i, \hat{y}^{(t-1)})$ .

### 2.8.4 Xây dựng cây (Tree Booster)

- Ở mỗi nút, với tập dữ liệu  $I$ , tính score tách:

$$\text{Gain} = \frac{1}{2} \left( \frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right) - \gamma,$$

trong đó  $G_{L,R} = \sum_{i \in I_{L,R}} g_i$ ,  $H_{L,R} = \sum_{i \in I_{L,R}} h_i$ .

- Chọn tách có Gain lớn nhất, dừng khi Gain âm hoặc đạt độ sâu tối đa.

### 2.8.5 Các tham số chính

- **eta** ( $\eta$ ): learning rate, giảm quy mô mỗi bước boosting.
- **max\_depth**: độ sâu tối đa của mỗi cây.
- **min\_child\_weight**: số lượng mẫu tối thiểu trong mỗi lá.
- **subsample**, **colsample\_bytree**: tỷ lệ lấy mẫu dòng và cột để tránh overfitting.
- **gamma** ( $\gamma$ ), **lambda** ( $\lambda$ ): hệ số regularization trên số lá và trọng số lá.

### 2.8.6 Ưu điểm và nhược điểm

- **Ưu điểm:**
  - + Hiệu năng cao, tối ưu song song và khả năng mở rộng.
  - + Xử lý thiếu giá trị tự động và regularization mạnh.
  - + Dễ điều chỉnh tham số để cân bằng bias–variance.
- **Nhược điểm:**
  - + Cấu hình tham số phức tạp, cần tinh chỉnh kỹ.
  - + Tiêu tốn tài nguyên tính toán trên dữ liệu rất lớn.

### 2.8.7 Ứng dụng

- Cuộc thi Kaggle và các bài toán dự đoán cạnh tranh.
- Hệ thống khuyến nghị (recommendation systems).
- Phân tích tín dụng và dự đoán rủi ro tài chính.
- Chẩn đoán y tế và phân tích y sinh.
- Dự báo chuỗi cung ứng và bảo trì dự báo.

## 2.9 TF-IDF vector

### 2.9.1 Khái niệm

TF-IDF (Term Frequency - Inverse Document Frequency) là một phương pháp chuyển đổi văn bản thành vector số để có thể xử lý bằng các thuật toán Machine Learning.

Mục đích chính: Đo tầm quan trọng của một từ (term) trong một tài liệu cụ thể trong toàn bộ tập tài liệu.



### 2.9.2 Các thành phần của TF-IDF

TF-IDF là tích của hai thành phần: Term Frequency (TF) và Inverse Document Frequency (IDF).

a. Term Frequency (TF)

TF đo mức độ xuất hiện của từ trong một tài liệu cụ thể:

$$TF(t, d) = \frac{t_d}{sum_d}$$

Với:

- +  $t_d$ : Số lần xuất hiện của  $t$  trong  $d$ .
- +  $sum_d$ : tổng số từ trong  $d$ .

Ý nghĩa:

- + Nếu một từ xuất hiện nhiều trong văn bản, nó có thể quan trọng.
- + Nhưng nếu xuất hiện trong mọi văn bản thì nó lại không đặc trưng  $\rightarrow$  cần IDF.

b. Inverse Document Frequency (IDF)

IDF giảm ảnh hưởng của những từ phổ biến, tăng trọng số cho từ hiếm nhưng đặc trưng:

$$IDF(t, D) = \log\left(\frac{N}{df_t}\right)$$

Với:

- +  $N$ : Tổng số tài liệu trong tập hợp văn bản  $D$ .
- +  $df_t$ : số tài liệu chứa từ  $t$ .

Ý nghĩa:

- + Từ xuất hiện trong nhiều tài liệu sẽ có IDF thấp.
- + Từ chỉ xuất hiện trong vài tài liệu  $\rightarrow$  IDF cao  $\rightarrow$  quan trọng hơn.

### 2.9.3 Kết luận

Khi nhân TF với IDF, ta có:


- Từ xuất hiện nhiều trong một tài liệu  $\rightarrow$  TF cao
- Nhưng không xuất hiện nhiều trong toàn bộ tập tài liệu  $\rightarrow$  IDF cao
- TF-IDF cao  $\rightarrow$  từ đó có tính đặc trưng cho tài liệu

## 2.10 PhoBERT

### 2.10.1 BERT

BERT (Bidirectional Encoder Representations from Transformers) [1] là một mô hình embedding ngôn ngữ do Google phát triển, dựa trên kiến trúc Transformer. BERT sử dụng cơ chế tự chú ý (self-attention) để hiểu các mối quan hệ ngữ cảnh giữa các từ trong câu, bất kể khoảng cách vị trí của chúng. BERT được huấn luyện trên 2 mục tiêu chính:

- **Masked Language Model (MLM)**: Dự đoán các từ bị che ngẫu nhiên trong câu để mô hình học ngữ nghĩa ngữ cảnh hai chiều.
- **Next Sentence Prediction (NSP)**: Xác định xem một câu có logic tiếp nối câu trước hay không, hỗ trợ cho các tác vụ liên quan đến mối quan hệ giữa các câu.



Hình 1: BERT

Do được tiền huấn luyện (pretrain) trên tập dữ liệu văn bản khổng lồ, khả năng tinh chỉnh cho các tác vụ cụ thể (finetune) đã biến BERT trở thành nền tảng trong xử lý ngôn ngữ tự nhiên (NLP).

### 2.10.2 RoBERTa

RoBERTa (Robustly Optimized BERT Pretraining Approach) [2] cải tiến BERT bằng cách thay đổi đáng kể phương pháp huấn luyện.

- **Loại bỏ Next Sentence Prediction**: RoBERTa bỏ qua NSP, chỉ tập trung vào nhiệm vụ MLM, đơn giản hóa quá trình huấn luyện nhưng vẫn duy trì hiệu suất cao.
- **Dynamic Masking**: RoBERTa áp dụng kỹ thuật Dynamic Masking thay vì Static Masking như BERT, thay đổi các token bị che trong suốt quá trình huấn luyện, giúp học được ngữ nghĩa đa dạng hơn.
- **Tăng kích thước Dataset và số Epochs**: RoBERTa được huấn luyện trên tập dữ liệu lớn hơn, nhiều epoch hơn, với kích thước batch lớn hơn.

- **Tăng từ vựng:** Kích thước từ vựng được mở rộng lên khoảng 50.000 token, giúp mô hình nắm bắt được nhiều ngữ nghĩa hơn từ các tập dữ liệu đa dạng.

Những tối ưu hóa này giúp RoBERTa đạt hiệu suất hàng đầu trên nhiều benchmark NLP.

### 2.10.3 PhoBERT

PhoBERT [3] là một mô hình pretrain chuyên biệt cho tiếng Việt, dựa trên kiến trúc RoBERTa, với các bước tiền xử lý bổ sung để xử lý đặc điểm riêng của văn bản tiếng Việt. Các đặc điểm chính:

- **Tokenizer tùy chỉnh:** Bộ tokenizer (bộ tách văn bản thành các token) được tối ưu cho tiếng Việt, tách từ hiệu quả hơn và nắm bắt tốt hơn các đơn vị subword đặc trưng của tiếng Việt.
- **Huấn luyện trên tập dữ liệu tiếng Việt:** PhoBERT được tiền huấn luyện trên các tập dữ liệu văn bản tiếng Việt lớn để có thể hiểu ngữ nghĩa tiếng Việt.

Những điều chỉnh này giúp cho PhoBERT trở thành một giải pháp mạnh mẽ cho các tác vụ xử lý văn bản tiếng Việt.

## 3 Thí nghiệm

### 3.1 Dữ liệu

- Dữ liệu gồm giá về các cổ phiếu, tin tức về các cổ phiếu trong ngày được lấy thư viện stock của python và api của Fireant.
- Cổ phiếu gồm 164 mã trên các sàn chứng khoán của Việt Nam bao gồm: VCB, BID, CTG, TCB, VPB, SSL, VCI, VND, HCM, VIX, BVH, PVI, VNR, BIC, MIG, ACV, GMD, PHP, CII, MVN, VTP, HUT, VCG, CTR, HVN, VJC, SKG, BSG, VNS, DL1, VEA, GEE, GEX, RAL, PAC, VEF, TLG, BCG, TVC, ITS, VIC, VHM, BCM, VRE, SSH, VNM, MSN, QNS, VSF, KDC, MCH, VMD, SAB, SBB, SMB, SGT, MTA, FIT, CLX, DLG, LIX, KSD, VGI, FOX, TTN, MFS, ABC, SBD, FPT, CMG, ELC, FOC, SAM, UNI, ONE, PSD, VEC, ICT, ST8, HPG, KSV, MSR, HSG, NKG, DGC, DCM, DPM, CSV, VFG, THD, HT1, LIC, KSB, VLB, VIF, ACG, HHP, TEG, AAA, TDP, DHC, MZG, GVR, TCH, PHR, DPR, HHS, MWG, PNJ, FRT, DGW, IPA, VGC, DNP, NTP, VCS, ASM, VGT, MSH, TCM, TNG, STK, PTB, TTF, GDT, NAG, SAV, EVE, YEG, VNB, ODE, EID, VNG, VTR, DSN, GAS, BSR, PLX, OIL, SWC, PLC, PVS, PVD, PVT, TOS, TMB, CST, TVD, AAH, DDG, REE, POW, PGV, VSH, BWE, TDM, CNG, DHG, DHT, IMP, DVN, DBD, TNH, JVC.
- Các mã cổ phiếu này được lựa chọn ngẫu nhiên trên nhiều ngành nghề sản xuất, công nghệ, công nghiệp, dịch vụ, ... khác nhau, cũng như có trung bình khối lượng giao dịch hơn 10000 cổ phiếu/ngày.
- Dữ liệu được lấy trong 2 năm gần đây nhất từ ngày 30-03-2023 đến 30-03-2025

#### 3.1.1 Dữ liệu về giá của các cổ phiếu

Trong phần này, chúng em trình bày cấu trúc chi tiết của bảng dữ liệu giá cổ phiếu. Dữ liệu được lấy từ stock python và lưu vào trong csv file có các cột (columns) như sau:

Bảng 1: Các biến trong dữ liệu giá cổ phiếu

| Tên biến | Mô tả                       |
|----------|-----------------------------|
| time     | Ngày giao dịch (YYYY-MM-DD) |
| open     | Giá mở cửa trong ngày       |
| high     | Giá cao nhất trong ngày     |
| low      | Giá thấp nhất trong ngày    |
| close    | Giá đóng cửa trong ngày     |
| volume   | Khối lượng giao dịch        |

Một ví dụ minh họa một vài dòng đầu của dữ liệu:

|   | time       | open  | high  | low   | close | volume |
|---|------------|-------|-------|-------|-------|--------|
| 0 | 2023-03-30 | 52.27 | 52.78 | 52.10 | 52.50 | 411004 |
| 1 | 2023-03-31 | 52.56 | 52.78 | 51.26 | 51.77 | 951283 |
| 2 | 2023-04-03 | 51.93 | 52.61 | 51.65 | 52.56 | 737481 |
| 3 | 2023-04-04 | 52.56 | 52.61 | 51.88 | 52.10 | 270521 |
| 4 | 2023-04-05 | 52.27 | 52.27 | 51.60 | 52.16 | 336349 |

Hình 2: Stock data from stock python

### 3.1.2 Dữ liệu về tin tức của các cổ phiếu

Phần này mô tả cấu trúc dữ liệu thu thập từ API Fireant. Mỗi bản ghi (record) ứng với một bản tin (news item) được lưu trong file json với các trường chính như sau:

Bảng 2: Các biến trong dữ liệu tin tức cổ phiếu

| Tên biến      | Mô tả                                                        |
|---------------|--------------------------------------------------------------|
| date          | Ngày bài báo được đăng                                       |
| title         | Tiêu đề của bài báo                                          |
| description   | Tóm tắt mô tả về thông tin bài báo                           |
| content       | Nội dung về bài báo                                          |
| taggedSymbols | Thông tin về những mã cổ phiếu liên quan được bài báo đề cập |

Ví dụ minh họa một vài dòng đầu:

|   | day        | date                          | title                                              | description                                       | content                                                      | taggedSymbols                                      | taggedSymbol |
|---|------------|-------------------------------|----------------------------------------------------|---------------------------------------------------|--------------------------------------------------------------|----------------------------------------------------|--------------|
| 0 | 2025-04-20 | 2025-04-20T19:00:00+07:00     | Đổi mới sáng tạo để nâng tầm thương hiệu quốc gia  | Xây dựng thương hiệu quốc gia là quá trình lâu... | <p><strong>Xây dựng thương hiệu quốc gia là quá trình lâu... | [{"symbol": "BID", "price": 35.95, "change": 0...} | BID          |
| 1 | 2025-04-19 | 2025-04-19T06:06:00+07:00     | Chiếm đoạt gần 49 tỷ đồng, cựu nhân viên ngân hàng | Ngoài án tù cho cựu nhân viên ngân hàng, Cơ qu... | <p><strong>Ngoài án tù cho cựu nhân viên ngân hàng, Cơ qu... | [{"symbol": "VCB", "price": 58.1, "change": 0...}  | VCB          |
| 2 | 2025-04-18 | 2025-04-18T15:36:00+07:00     | VCB: Báo cáo thường niên năm 2024                  | VCB: Báo cáo thường niên năm 2024                 | <p>Ngân hàng Thương mại Cổ phần Ngoại Thương V...            | [{"symbol": "VCB", "price": None, "change": 0...}  | VCB          |
| 3 | 2025-04-18 | 2025-04-18T07:16:00+07:00     | Đầu tư công tăng tốc - Tăng triển vọng với nhà...  | Trong năm 2025, nhóm phiếu cổ ngân hàng quốc d... | <p><strong>Trong năm 2025, nhóm phiếu cổ ngân hàng quốc d... | [{"symbol": "BID", "price": 35.85, "change": 0...} | BID          |
| 4 | 2025-04-16 | 2025-04-16T17:16:00+07:00     | Vietcombank tung sản phẩm tín dụng "Nhà mới th...  | Hướng tới nhu cầu an cư của người trẻ, Ngân hà... | <p><strong>Hướng tới nhu cầu an cư của người trẻ, Ngân hà... | [{"symbol": "VCB", "price": 59.3, "change": 0...}  | VCB          |
| 5 | 2025-04-14 | 2025-04-14T17:45:00+07:00     | VCB: Thông báo thay đổi nhân sự công ty            | VCB: Thông báo thay đổi nhân sự công ty           | <p>Ngân hàng Thương mại Cổ phần Ngoại Thương V...            | [{"symbol": "VCB", "price": None, "change": 0...}  | VCB          |
| 6 | 2025-04-14 | 2025-04-14T17:33:00+07:00     | VCB: Thông báo giao dịch cổ phiếu của Người nộ...  | VCB: Thông báo giao dịch cổ phiếu của Người nộ... | <p>Phùng Nguyễn Hải Yến thông báo giao dịch cổ...            | [{"symbol": "VCB", "price": None, "change": 0...}  | VCB          |
| 7 | 2025-04-14 | 2025-04-14T08:40:32.993+07:00 | Danh mục cổ phiếu cần quan tâm hôm nay 14/4        | Trong phiên hôm nay, các cổ phiếu được công t...  | <p>\n\n<strong> Trong phiên hôm nay, các cổ ...              | [{"symbol": "CII", "price": None, "change": 0...}  | CII          |
| 8 | 2025-04-10 | 2025-04-10T11:21:00+07:00     | DBC: Ông Nguyễn Như So - Dabaco không bị ảnh h...  | Thỏa thuận hợp tác giữa Dabaco và Vietcombank ... | <p><strong>Thỏa thuận hợp tác giữa Dabaco và V...            | [{"symbol": "DBC", "price": 23.45, "change": 0...} | DBC          |
| 9 | 2025-04-09 | 2025-04-09T23:05:00+07:00     | VCB: Tăng vốn không ngừng nghỉ, Vietcombank gi...  | Năm 2025, Vietcombank dự kiến trình Đại hội đ...  | <p><strong> , <strong>, \r, \n, những link ảnh, ... nên nhóm sẽ quyết định loại bỏ các phần thừa này.

|      | time       | title                                             | content                                            | content2                                          |
|------|------------|---------------------------------------------------|----------------------------------------------------|---------------------------------------------------|
| 1785 | 2025-03-23 | Nhiều ngân hàng lớn đẩy mạnh kế hoạch tăng vốn... | <p><strong> Bước vào mùa Đại hội Đồng cổ đông ...  | bước vào mùa đại hội đồng cổ đông thường niên ... |
| 1786 | 2025-03-25 | Lãi suất Vietcombank tháng 3/2025, cao nhất 4,7%  | <p><strong> Trong tháng 3/2025, ngân hàng Vietc... | trong tháng ngân hàng vietcombank tiếp tục duy... |
| 1787 | 2025-03-25 | VIC: Vingroup áp sát top 3 doanh nghiệp niêm y... | <p>\n\n<strong>Liên tục tăng nóng từ đầu thá...    | liên tục tăng nóng từ đầu tháng cổ phiếu vic v... |
| 1788 | 2025-03-26 | Ngành ngân hàng quý 1/2025: Big 4 giữ vững pho... | <p><strong> Theo đánh giá của SSI, hầu hết các ... | theo đánh giá của ssi hầu hết các ngân hàng nà... |
| 1789 | 2025-03-27 | VCB: Báo cáo kết quả phát hành cổ phiếu để trả... | <p>Ngân hàng Thương mại Cổ phần Ngoại Thương V...  | ngân hàng thương mại cổ phần ngoại thương việt... |
| 1790 | 2025-03-27 | VCB: Thông báo thay đổi số lượng cổ phiếu có q... | <p>Ngân hàng Thương mại Cổ phần Ngoại Thương V...  | ngân hàng thương mại cổ phần ngoại thương việt... |
| 1791 | 2025-03-27 | Vietcombank chính thức thành ngân hàng có vốn ... | <p><strong> Vietcombank đã phát hành xong hơn 2... | vietcombank đã phát hành xong hơn tỷ cổ phiếu ... |
| 1792 | 2025-03-27 | Vietcombank mở rộng quy mô cho vay nông, lâm, ... | <p><strong> Ngân hàng TMCP Ngoại thương Việt N...  | ngân hàng tmcp ngoại thương việt nam vietcomba... |
| 1793 | 2025-03-29 | Cập nhật mới nhất tỷ lệ nắm giữ của khối ngoại... | <p><strong> Theo số liệu cập nhật mới nhất của...  | theo số liệu cập nhật mới nhất của trung tâm l... |
| 1794 | 2025-03-29 | Lực cầu vẫn tiềm ẩn trên thị trường chứng khoán   | <p><strong> Áp lực bán đang hiện hữu trên TTCK...  | áp lực bán đang hiện hữu trên ttc nhưng chỉ s...  |

Hình 4: content là dữ liệu tin tức nguyên mẫu, content2 là dữ liệu đã được tiền xử lý.

## 3.2 Dataset

### 3.2.1 Dữ liệu giá chứng khoán

Do bản chất nhiễu của dữ liệu giá cổ phiếu, việc xây dựng mô hình để đoán trực tiếp giá cổ phiếu của ngày hôm sau là khó khả thi, dễ dẫn đến việc mô hình có thể bị Underfit hoặc Overfit. Vì vậy, chúng em đề xuất chỉ dự đoán xu hướng của cổ phiếu đó trong 7 ngày giao dịch của tương lai với các nhãn (Label) gồm: "up" (Tăng), "down" (Giảm) và "sideways" (Đi ngang). Nhãn của ngày  $t_0$  sẽ được xác định theo hệ số góc của của đường Hồi qui tuyến tính dựa trên giá đóng cửa đã được chuẩn hoá của ngày  $t_0, t_1, \dots, t_6$  (ngày đang xét, ngày tiếp theo của ngày đang xét, ...). Việc chuẩn hoá này xuất phát từ thực tế là giá trị của các 1 cổ phiếu của các mã khác nhau thì khác nhau, và giá tăng hoặc giảm của 1 cổ phiếu thường được biểu hiện bằng %.

Cụ thể hơn, đặt  $close_{t_0}, close_{t_1}, \dots, close_{t_6}$  ứng với giá đóng cửa của ngày đang xét. Đặt  $c_{t_0}, c_{t_1}, \dots, c_{t_6}$  là giá đóng cửa đã được chuẩn hoá. Đặt  $y = a * x + b$  là đường thẳng hồi quy tuyến tính,  $a$  là hệ số góc,  $b$  là giao điểm của đường thẳng với trục y.

Ta có:

$$c_{t_i} = \frac{close_{t_i}}{close_{t_0}} \text{ với } i = 0, 1, \dots, 6$$

Dễ thấy  $c_{t_0} = 1$ .

Đường thẳng  $y = a * x + b$  khớp nhất với tập điểm  $(i, c_{t_i})$  với  $i = 0, 1, \dots, 6$

$$Label_{t_0} := \begin{cases} \text{"up"} & \text{if } a \geq threshold \\ \text{"sideways"} & \text{if } -threshold < a < threshold \\ \text{"down"} & \text{if } a \leq -threshold \end{cases}$$

Với  $threshold = \frac{0.03}{7}$  ứng với việc biến động 3% trong 7 ngày giao dịch của tương lai.

Việc đánh giá mô hình sẽ được thực hiện bằng cách lấy tất cả dữ liệu (bao gồm lịch sử giá và tin tức) của mỗi mã cổ phiếu đến ngày  $t$  để huấn luyện mô hình, rồi thực hiện dự đoán xu hướng của 7 ngày tiếp theo bắt đầu từ  $t$ . Dữ liệu huấn luyện đảm bảo có ít nhất 90 ngày.



|     | time       | open  | high  | low   | close | volume  | close_t0 | close_t1 | close_t2 | close_t3 | close_t4 | close_t5 | close_t6 | coef_close_t0_to_close_t6 | ground_truth |
|-----|------------|-------|-------|-------|-------|---------|----------|----------|----------|----------|----------|----------|----------|---------------------------|--------------|
| 392 | 2024-10-23 | 61.00 | 61.41 | 61.00 | 61.20 | 750353  | 1.0      | 1.002288 | 1.003431 | 1.005556 | 1.005556 | 1.002288 | 1.023039 | 0.002544                  | sideways     |
| 358 | 2024-09-05 | 60.60 | 60.94 | 60.27 | 60.27 | 1185511 | 1.0      | 1.000996 | 1.000996 | 0.987722 | 0.981085 | 0.993363 | 0.997677 | -0.001505                 | sideways     |
| 443 | 2025-01-03 | 61.47 | 61.81 | 61.47 | 61.54 | 1403040 | 1.0      | 1.009750 | 1.003250 | 1.004387 | 0.998863 | 0.993500 | 0.998863 | -0.001439                 | sideways     |
| 476 | 2025-02-26 | 61.94 | 62.14 | 61.67 | 61.74 | 771099  | 1.0      | 1.018465 | 1.010852 | 1.010852 | 1.007613 | 1.007613 | 1.012958 | 0.000497                  | sideways     |
| 270 | 2024-05-02 | 61.61 | 61.87 | 60.94 | 61.47 | 933709  | 1.0      | 1.006507 | 1.012038 | 1.010900 | 1.012038 | 1.006507 | 1.001139 | 0.000122                  | sideways     |
| 83  | 2023-07-28 | 62.01 | 62.21 | 61.41 | 62.21 | 1118204 | 1.0      | 0.984890 | 0.980550 | 0.983765 | 0.974120 | 0.968815 | 0.976370 | -0.003910                 | sideways     |
| 179 | 2023-12-13 | 56.32 | 56.52 | 55.99 | 55.99 | 1154515 | 1.0      | 1.008394 | 0.981961 | 0.973745 | 0.969995 | 0.968923 | 0.966423 | -0.006844                 | down         |
| 425 | 2024-12-09 | 63.01 | 63.75 | 62.81 | 63.75 | 1958838 | 1.0      | 0.991529 | 0.978980 | 0.981020 | 0.976784 | 0.976784 | 0.975843 | -0.003720                 | sideways     |
| 412 | 2024-11-20 | 60.20 | 61.00 | 60.13 | 60.40 | 1641687 | 1.0      | 1.002318 | 1.003311 | 1.011093 | 1.023344 | 1.026656 | 1.025497 | 0.005186                  | up           |
| 144 | 2023-10-25 | 56.92 | 57.39 | 56.59 | 57.39 | 660885  | 1.0      | 0.984841 | 0.990765 | 1.001220 | 1.011675 | 1.023349 | 1.037289 | 0.007493                  | up           |

Hình 5: Dataset - Một vài dòng ngẫu nhiên từ mã cổ phiếu VCB

### 3.2.2 Dữ liệu tin tức hằng ngày

Tin tức dữ liệu chứng khoán hằng ngày được mang qua một mạng embedding để đưa ra thành một vector. Ở bài báo cáo này nhóm có dùng 2 cách embedding, một phương pháp machine learning là TF-IDF và một phương pháp của deep learning là roberta.

- TF-IDF vector: Chuẩn hóa bài thành vector tối đa 5000 features. Vector tin tức của một ngày được tính trung bình từ tất cả các bài báo trong ngày.

|       | 0   | 1   | 2        | 3   | 4   | 5   | 6   | 7   | 8   | 9   | ... | 4990 | 4991 | 4992 | 4993     | 4994     | 4995 | 4996     | 4997 | 4998 | 4999     |
|-------|-----|-----|----------|-----|-----|-----|-----|-----|-----|-----|-----|------|------|------|----------|----------|------|----------|------|------|----------|
| 21421 | 0.0 | 0.0 | 0.000000 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | ... | 0.0  | 0.0  | 0.0  | 0.000000 | 0.018279 | 0.0  | 0.000000 | 0.0  | 0.0  | 0.000000 |
| 15280 | 0.0 | 0.0 | 0.000000 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | ... | 0.0  | 0.0  | 0.0  | 0.000000 | 0.005821 | 0.0  | 0.009969 | 0.0  | 0.0  | 0.016475 |
| 7892  | 0.0 | 0.0 | 0.000000 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | ... | 0.0  | 0.0  | 0.0  | 0.022754 | 0.000000 | 0.0  | 0.000000 | 0.0  | 0.0  | 0.000000 |
| 21219 | 0.0 | 0.0 | 0.425734 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | ... | 0.0  | 0.0  | 0.0  | 0.000000 | 0.000000 | 0.0  | 0.000000 | 0.0  | 0.0  | 0.025522 |
| 12003 | 0.0 | 0.0 | 0.000000 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | 0.0 | ... | 0.0  | 0.0  | 0.0  | 0.000000 | 0.000000 | 0.0  | 0.000000 | 0.0  | 0.0  | 0.000000 |

Hình 6: Một vài dữ liệu bài báo mẫu sau khi qua TF-IDF

- PhoBert: PhoBert là mô hình được finetune lại từ kiến trúc của roberta, PhoBert biểu diễn một bài báo thành một vector 768 feature. Cũng như TF-IDF, vector tin tức của một ngày được tính trung bình từ tất cả các bài báo trong ngày.

|       | 0         | 1        | 2         | 3         | 4         | 5        | 6         | 7         | 8         | 9         | ... | 758       | 759       | 760      | 761       | 762       | 763       | 764       | 765       | 766       | 767      |
|-------|-----------|----------|-----------|-----------|-----------|----------|-----------|-----------|-----------|-----------|-----|-----------|-----------|----------|-----------|-----------|-----------|-----------|-----------|-----------|----------|
| 638   | -0.071664 | 0.393990 | -0.076427 | -0.011497 | -0.213647 | 0.119202 | -0.033933 | -0.225235 | -0.035657 | 0.018210  | ... | -0.214097 | -0.062935 | 0.215654 | 0.063975  | -0.082491 | 0.105157  | -0.060793 | 0.032931  | -0.088783 | 0.184061 |
| 7807  | -0.103523 | 0.334129 | -0.117347 | -0.040494 | -0.318721 | 0.228505 | 0.220469  | -0.266105 | 0.006284  | 0.075965  | ... | -0.317305 | -0.043181 | 0.101409 | 0.083518  | -0.176302 | 0.149807  | -0.071536 | 0.022906  | -0.110737 | 0.134599 |
| 21290 | -0.037228 | 0.418105 | -0.168889 | -0.099511 | -0.413804 | 0.255597 | 0.253183  | -0.380538 | 0.038146  | -0.037016 | ... | -0.469756 | -0.089402 | 0.119785 | 0.281110  | -0.111822 | 0.167636  | -0.022178 | 0.056308  | -0.092857 | 0.214645 |
| 20492 | -0.173067 | 0.461707 | -0.150000 | 0.088906  | -0.167507 | 0.242979 | 0.200291  | -0.321815 | 0.012417  | 0.114009  | ... | -0.537863 | 0.024344  | 0.142338 | 0.145316  | -0.135494 | 0.039337  | -0.054450 | 0.017080  | -0.077255 | 0.350764 |
| 10442 | -0.075023 | 0.468102 | -0.126072 | -0.092907 | -0.204118 | 0.153995 | 0.106255  | -0.408454 | -0.070672 | -0.034724 | ... | -0.307347 | -0.124357 | 0.196137 | -0.048775 | -0.180505 | 0.093290  | -0.079482 | 0.120210  | 0.063403  | 0.257345 |
| 18    | -0.300457 | 0.378219 | -0.158308 | -0.436114 | -0.377577 | 0.178579 | 0.199902  | -0.339791 | 0.073788  | -0.103309 | ... | -0.357279 | -0.112791 | 0.017257 | -0.064493 | -0.223400 | 0.018160  | 0.212876  | 0.067467  | -0.086310 | 0.272043 |
| 544   | -0.206616 | 0.360416 | -0.077285 | -0.101688 | -0.176662 | 0.098893 | 0.003590  | -0.346760 | 0.016828  | 0.114815  | ... | -0.513903 | 0.025577  | 0.233413 | 0.033585  | -0.115109 | 0.052288  | -0.090616 | 0.057493  | -0.127562 | 0.303211 |
| 19645 | -0.129828 | 0.268154 | -0.181162 | -0.001823 | -0.352423 | 0.185174 | 0.218936  | -0.304139 | -0.054932 | 0.041834  | ... | -0.434432 | -0.121372 | 0.130641 | 0.075490  | -0.102687 | 0.098797  | -0.089952 | 0.024700  | -0.033429 | 0.143498 |
| 10400 | -0.277354 | 0.446745 | -0.172820 | -0.335433 | -0.221027 | 0.215578 | 0.288645  | -0.206569 | 0.035951  | 0.017669  | ... | -0.617961 | -0.021258 | 0.007900 | -0.022962 | -0.179429 | -0.083019 | 0.203045  | 0.088796  | -0.080904 | 0.412444 |
| 6823  | -0.142534 | 0.380637 | -0.135030 | 0.170600  | -0.310921 | 0.275226 | 0.155433  | -0.219468 | -0.061164 | -0.007190 | ... | -0.153834 | -0.080262 | 0.161310 | 0.074191  | -0.131761 | -0.028610 | -0.027819 | -0.040920 | -0.020946 | 0.126483 |

Hình 7: Một vài dữ liệu bài báo mẫu sau khi qua PhoBert

zZDữ liệu sau khi được gom lại từ ngày 30-03-2023 đến 30-03-2025 do có những ngày không có tin tức và không có giá của cổ phiếu nên data cuối của nhóm được chia thành tập train từ 30-03-2023 đến 30-01-2025 và tập test từ 30-01-2025 đến 30-03-2025 để đảm bảo model không biết trước được giá trị của những ngày trong tương lai với 23193 dòng cho train và 2077 cho test



|       | 0         | 1        | 2         | 3         | 4         | 5        | 6         | 7         | 8         | 9         | ... | 758       | 759       | 760       | 761       |        |
|-------|-----------|----------|-----------|-----------|-----------|----------|-----------|-----------|-----------|-----------|-----|-----------|-----------|-----------|-----------|--------|
| 0     | -0.048757 | 0.420739 | -0.157843 | 0.030076  | -0.300998 | 0.203859 | 0.240796  | -0.276923 | -0.051853 | 0.061908  | ... | -0.438060 | 0.098128  | 0.133396  | 0.125719  | -0.078 |
| 1     | -0.084004 | 0.358260 | -0.118248 | 0.007462  | -0.266135 | 0.274548 | 0.165371  | -0.326678 | -0.109861 | 0.017614  | ... | -0.321613 | -0.016240 | 0.207875  | 0.201610  | -0.079 |
| 2     | 0.011677  | 0.510123 | -0.157833 | 0.158835  | -0.149963 | 0.239865 | 0.034044  | -0.293104 | -0.051458 | 0.083048  | ... | -0.431448 | 0.068814  | 0.182915  | 0.134339  | -0.099 |
| 3     | -0.295156 | 0.368637 | -0.185800 | -0.529467 | -0.417908 | 0.101463 | 0.195674  | -0.281929 | 0.049354  | -0.132261 | ... | -0.302709 | -0.048095 | -0.036727 | -0.091963 | -0.293 |
| 4     | -0.144884 | 0.437191 | -0.162050 | -0.077133 | -0.227116 | 0.207047 | 0.028807  | -0.355564 | -0.054852 | 0.062768  | ... | -0.442269 | -0.069211 | 0.364604  | 0.025173  | -0.084 |
| ...   | ...       | ...      | ...       | ...       | ...       | ...      | ...       | ...       | ...       | ...       | ... | ...       | ...       | ...       | ...       | ...    |
| 23188 | -0.134704 | 0.297841 | 0.012767  | -0.133531 | -0.169652 | 0.174451 | -0.128860 | -0.319666 | -0.010653 | -0.021331 | ... | -0.351595 | -0.129051 | 0.112135  | 0.156133  | -0.003 |
| 23189 | -0.143952 | 0.330089 | -0.116870 | 0.005337  | -0.207046 | 0.082949 | 0.024727  | -0.384219 | 0.163593  | 0.008934  | ... | -0.267207 | -0.030871 | 0.186091  | 0.120005  | 0.006  |
| 23190 | -0.115904 | 0.320955 | -0.071730 | -0.170820 | -0.241000 | 0.176570 | 0.176852  | -0.344843 | -0.128409 | 0.053103  | ... | -0.292376 | -0.083589 | 0.100203  | 0.002616  | -0.138 |
| 23191 | -0.122357 | 0.323152 | 0.018953  | -0.026720 | -0.049256 | 0.145084 | -0.096268 | -0.255896 | -0.064444 | 0.060876  | ... | -0.390380 | -0.176348 | 0.298463  | -0.049398 | -0.052 |
| 23192 | -0.106355 | 0.375210 | -0.152698 | -0.088200 | -0.169004 | 0.098649 | 0.201472  | -0.231166 | -0.058457 | 0.080044  | ... | -0.539234 | -0.102622 | 0.102362  | -0.035377 | -0.189 |

23193 rows x 768 columns

Hình 8: Data train

|      | 0         | 1        | 2         | 3         | 4         | 5        | 6        | 7         | 8         | 9         | ... | 758       | 759       | 760       | 761       | 76       |
|------|-----------|----------|-----------|-----------|-----------|----------|----------|-----------|-----------|-----------|-----|-----------|-----------|-----------|-----------|----------|
| 0    | -0.062199 | 0.358529 | -0.125282 | -0.053592 | -0.175605 | 0.145500 | 0.055102 | -0.286718 | 0.064079  | 0.106228  | ... | -0.382560 | -0.005657 | 0.184538  | 0.181135  | -0.09009 |
| 1    | -0.122721 | 0.364638 | -0.074682 | 0.122965  | -0.143032 | 0.276070 | 0.107645 | -0.231048 | 0.079442  | 0.208852  | ... | -0.316337 | 0.056770  | 0.161388  | 0.143490  | -0.13601 |
| 2    | -0.098518 | 0.323946 | -0.036259 | -0.034465 | -0.089672 | 0.178385 | 0.067865 | -0.292310 | 0.107854  | 0.192767  | ... | -0.353502 | -0.019395 | 0.161244  | 0.093544  | -0.13659 |
| 3    | -0.118572 | 0.381150 | -0.121289 | -0.063245 | -0.197296 | 0.246804 | 0.129058 | -0.262761 | 0.114418  | 0.012817  | ... | -0.423964 | 0.016659  | 0.235239  | 0.052398  | -0.12680 |
| 4    | -0.349098 | 0.458353 | -0.210135 | -0.454828 | -0.339558 | 0.341328 | 0.202532 | -0.342434 | 0.018721  | -0.119741 | ... | -0.279219 | -0.078280 | -0.033347 | -0.195230 | -0.22994 |
| ...  | ...       | ...      | ...       | ...       | ...       | ...      | ...      | ...       | ...       | ...       | ... | ...       | ...       | ...       | ...       | ...      |
| 2072 | -0.190962 | 0.329068 | -0.214971 | -0.148211 | -0.154639 | 0.046904 | 0.230027 | -0.227032 | -0.068414 | -0.006253 | ... | -0.617003 | -0.054421 | 0.106773  | 0.101797  | -0.08397 |
| 2073 | -0.092687 | 0.185504 | -0.109084 | -0.098883 | -0.152295 | 0.076840 | 0.046082 | -0.254573 | -0.031451 | -0.005140 | ... | -0.275710 | -0.201835 | 0.108987  | 0.033165  | -0.10756 |
| 2074 | -0.191491 | 0.346253 | -0.177649 | -0.115715 | -0.269674 | 0.116089 | 0.047978 | -0.246641 | 0.025628  | 0.035819  | ... | -0.536733 | 0.012016  | 0.111323  | 0.153898  | -0.02607 |
| 2075 | -0.057346 | 0.423258 | -0.219992 | -0.115589 | -0.149921 | 0.128351 | 0.178456 | -0.276404 | -0.093070 | 0.008434  | ... | -0.320284 | -0.080315 | 0.212631  | 0.145697  | -0.14218 |
| 2076 | -0.172458 | 0.316004 | -0.186032 | -0.092266 | -0.187300 | 0.113397 | 0.120228 | -0.191061 | 0.062053  | 0.096415  | ... | -0.420683 | 0.028997  | 0.241982  | 0.086031  | -0.12154 |

2077 rows x 768 columns

Hình 9: Data test

### 3.3 Linear Regression - Baseline

Ta áp dụng mô hình Hồi quy tuyến tính bằng cách lấy dữ liệu giá lịch sử của 7 ngày gần nhất để dự đoán 7 ngày tiếp theo. Cách thức xây dựng mô hình giống với khi xây dựng **Dataset**, tuy nhiên đường thẳng hồi quy sẽ khớp với dữ liệu từ ngày  $(i, c_{t_i})$  với  $i = -6, -5, \dots, -1, 0$ , và việc chuẩn hoá sẽ thực hiện trên ngày  $t_{-6}$ .

Cụ thể, Ta có:

$$c_{t_i} = \frac{close_{t_i}}{close_{t_{-6}}} \text{ với } i = -6, -5, \dots, -1, 0$$

Để thấy  $c_{t_{-6}} = 1$ .

Đường thẳng  $y = a * x + b$  khớp nhất với tập điểm  $(i + 6, c_{t_i})$  với  $i = -6, -5, \dots, -1, 0$

$$Predict_{t_0} := \begin{cases} \text{"up"} & \text{if } a \geq threshold \\ \text{"sideways"} & \text{if } -threshold < a < threshold \\ \text{"down"} & \text{if } a \leq -threshold \end{cases}$$

Với  $threshold = \frac{0.03}{7}$  ứng với việc biến động 3% trong 7 ngày giao dịch.

Do cách tiếp cận này khá ngây thơ, và cũng không sử dụng đến dữ liệu tin tức, nên ta sẽ dùng kết quả của mô hình này để làm Baseline cho bài toán.





|     | time       | close | coef_close_t0_to_close_t6 | ground_truth | close_t-6 | close_t-5 | close_t-4 | close_t-3 | close_t-2 | close_t-1 | close_t0 | coef_close_t-6_to_close_t0 | predict  |
|-----|------------|-------|---------------------------|--------------|-----------|-----------|-----------|-----------|-----------|-----------|----------|----------------------------|----------|
| 300 | 2024-06-13 | 59.13 | -0.004306                 | down         | 1.0       | 1.002189  | 0.996633  | 0.990909  | 0.981987  | 0.998822  | 0.995455 | -0.001251                  | sideways |
| 158 | 2023-11-14 | 57.53 | -0.000838                 | sideways     | 1.0       | 0.986471  | 1.000000  | 0.982128  | 0.960915  | 0.955236  | 0.960915 | -0.007815                  | down     |
| 455 | 2025-01-21 | 61.14 | 0.001682                  | sideways     | 1.0       | 0.997885  | 0.994632  | 1.008785  | 1.006507  | 0.997885  | 0.994632 | -0.000151                  | sideways |
| 143 | 2023-10-24 | 57.53 | 0.003650                  | sideways     | 1.0       | 0.997743  | 0.997743  | 0.981420  | 0.984893  | 0.981420  | 0.998958 | -0.001736                  | sideways |
| 454 | 2025-01-20 | 61.34 | 0.001048                  | sideways     | 1.0       | 1.005397  | 1.003271  | 1.000000  | 1.014230  | 1.011940  | 1.003271 | 0.001209                   | sideways |
| 360 | 2024-09-09 | 60.33 | 0.000894                  | sideways     | 1.0       | 1.004266  | 1.006564  | 0.998851  | 0.989006  | 0.989990  | 0.989990 | -0.002719                  | sideways |
| 84  | 2023-07-31 | 61.27 | -0.001894                 | sideways     | 1.0       | 0.996133  | 1.031444  | 1.050614  | 1.042711  | 1.046074  | 1.030267 | 0.007213                   | up       |
| 175 | 2023-12-07 | 56.99 | -0.004487                 | down         | 1.0       | 0.995432  | 0.998946  | 1.010717  | 1.003514  | 1.009487  | 1.001230 | 0.001299                   | sideways |
| 228 | 2024-02-28 | 65.15 | -0.003656                 | sideways     | 1.0       | 0.998854  | 0.980350  | 0.973801  | 0.980350  | 0.997871  | 1.066809 | 0.007088                   | up       |
| 104 | 2023-08-28 | 58.19 | 0.004978                  | up           | 1.0       | 1.003341  | 0.987640  | 0.964256  | 0.971939  | 0.963087  | 0.971939 | -0.006443                  | down     |

Hình 10: Lấy ngẫu nhiên một vài dự đoán trên cổ phiếu VCB.

Kết quả:

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| <b>down</b>         | 0.23146   | 0.23093 | 0.23120  | 16425   |
| <b>sideways</b>     | 0.60012   | 0.59876 | 0.59944  | 42737   |
| <b>up</b>           | 0.28258   | 0.28452 | 0.28355  | 19700   |
| <b>accuracy</b>     |           |         | 0.44365  | 78862   |
| <b>macro avg</b>    | 0.37139   | 0.37140 | 0.37139  | 78862   |
| <b>weighted avg</b> | 0.44401   | 0.44365 | 0.44383  | 78862   |

Bảng 3: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: THD (0.92900), SSH (0.89481), DSN (0.85326), ODE (0.80670), KDC (0.79055), SMB (0.78645), VSH (0.68952), EID (0.67432), VJC (0.64413), VNS (0.64403).
- Tệ nhất: MWG (0.33029), SKG (0.32258), VIF (0.31032), VGI (0.31017), MSR (0.30619), NKG (0.30144), PLC (0.30095), ELC (0.29997), BCG (0.29723), SBD (0.29518).

Nhận xét: Mô hình này dự đoán tốt với các cổ phiếu không có nhiều biến động trong tập dữ liệu.



Hình 11: Dự đoán tốt nhất - THD - Giá cổ phiếu phần lớn đi ngang - Nguồn hình Fireant/TradingView



Hình 12: Dự đoán tệ nhất - SBD - Giá cổ phiếu biến động mạnh - Nguồn hình Fireant/TradingView

### 3.4 Naive bayes

#### 3.4.1 TF-IDF

Với bài báo được embedding bằng TF-IDF ta sử dụng multinominal bayes do ta cần phân loại thành 3 lớp.

Ta sử dụng 5000 feature từ bài báo và thêm 1 feature về xu hướng của ngày hôm qua đến hôm nay và dự đoán về xu hướng trong 7 ngày tiếp theo.

Kết quả: Accuracy = 0.4383

|              | Precision | Recall  | F1-Score | Support |
|--------------|-----------|---------|----------|---------|
| down         | 0.48196   | 0.40476 | 0.44000  | 924     |
| sideways     | 0.51020   | 0.09328 | 0.15773  | 268     |
| up           | 0.40590   | 0.59542 | 0.48272  | 786     |
| accuracy     |           |         | 0.43832  | 1978    |
| macro avg    | 0.46602   | 0.36449 | 0.36015  | 1978    |
| weighted avg | 0.45556   | 0.43832 | 0.41873  | 1978    |

Bảng 4: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: SWC (1.0000), ODE (1.0000), TCH (1.0000), UNI (1.0000), VMD (1.0000), TVC (1.0000), VEF (1.0000), VNR (1.0000), VGI (0.6786), VNG (0.5833).
- Tệ nhất: BSG (0.0000), DL1 (0.0000), ITS (0.0000), SBB (0.0000), LIX (0.0000), KSD (0.0000), TTN (0.0000), ABC (0.0000), FOC (0.0000), SAM (0.0000).



Hình 13: Dự đoán tốt nhất - ODE - Nguồn hình Fireant/TradingView



Hình 14: Dự đoán tệ nhất - DL1 - Nguồn hình Fireant/TradingView

### 3.4.2 PhoBert

Với bài báo được embedding bằng PhoBert ta sử dụng gaussian bayes do data của multinomial bayes không chấp nhận các giá trị mang giá trị âm.

Ta sử dụng 768 feature từ bài báo và thêm 1 feature về xu hướng của ngày hôm qua đến hôm nay và dự đoán về xu hướng trong 7 ngày tiếp theo.

Kết quả: Accuracy = 0.3959

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| <b>down</b>         | 0.48497   | 0.40152 | 0.43931  | 924     |
| <b>sideways</b>     | 0.20000   | 0.27985 | 0.23328  | 268     |
| <b>up</b>           | 0.40215   | 0.42875 | 0.41502  | 786     |
| <b>accuracy</b>     |           |         | 0.39585  | 1978    |
| <b>macro avg</b>    | 0.36237   | 0.37004 | 0.36254  | 1978    |
| <b>weighted avg</b> | 0.41345   | 0.39585 | 0.40175  | 1978    |

Bảng 5: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: DDG (1.0000), PLC (1.0000), ODE (1.0000), VIF (1.0000), PSD (1.0000), UNI (1.0000), TTN (1.0000), KSD (1.0000), TVC (1.0000), VEF (1.0000).
- Tệ nhất: VNR (0.0000), BSG (0.0000), VEA (0.0000), ITS (0.0000), VSF (0.0000), SBB (0.0000), FIT (0.0000), MFS (0.0000), ABC (0.0000), FOC (0.0000).



Hình 15: Dự đoán tốt nhất - PLC - Nguồn hình Fireant/TradingView



Hình 16: Dự đoán tệ nhất - VNR - Nguồn hình Fireant/TradingView

Nhận xét: Mô hình hoạt động tốt với các cổ phiếu ảnh hưởng bởi tin tức.

### 3.5 Support vector machine

Ta sử dụng mô hình SVC để phân loại đa lớp (3 nhãn: *down*, *sideways*, *up*), với tham số  $\text{kernel} = \text{rbf}$  để mở không gian dữ liệu thành vô hạn chiều nhằm dễ phân tách tuyến tính,  $C = 1$ ,  $\text{gamma} = \text{"scale"}$  và  $\text{decision\_function\_shape}$  là ovo để xuất ra ma trận quyết định theo chiến lược one-vs-one để hình thành từng cặp nhị phân

### 3.5.1 TF-IDF vector

Kết quả: Accuracy = 0.4286

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| <b>down</b>         | 0.46459   | 0.41883 | 0.44052  | 924     |
| <b>sideways</b>     | 0.47222   | 0.12687 | 0.20000  | 268     |
| <b>up</b>           | 0.39776   | 0.54337 | 0.45930  | 784     |
| <b>accuracy</b>     |           |         | 0.42864  | 1976    |
| <b>macro avg</b>    | 0.44486   | 0.36302 | 0.36661  | 1976    |
| <b>weighted avg</b> | 0.43911   | 0.42864 | 0.41535  | 1976    |

Bảng 6: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: UNI (1.0000), FOC (1.0000), KSD (1.0000), VMD (1.0000), TVC (1.0000), VEF (1.0000), VEA (1.0000), PSD (0.6667), VGI (0.5846), VNG (0.5833).
- Tệ nhất: PVI (0.0000), VNR (0.0000), BSG (0.0000), ITS (0.0000), VSF (0.0000), SBB (0.0000), LIX (0.0000), TTN (0.0000), ABC (0.0000), VEC (0.0000).

### 3.5.2 PhoBert

Kết quả: Accuracy = 0.4281

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| <b>down</b>         | 0.46230   | 0.40476 | 0.43162  | 924     |
| <b>sideways</b>     | 0.46970   | 0.11567 | 0.18563  | 268     |
| <b>up</b>           | 0.40054   | 0.56250 | 0.46790  | 784     |
| <b>accuracy</b>     |           |         | 0.42814  | 1976    |
| <b>macro avg</b>    | 0.44418   | 0.36098 | 0.36172  | 1976    |
| <b>weighted avg</b> | 0.43880   | 0.42814 | 0.41265  | 1976    |

Bảng 7: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: VSH (1.0000), PLC (1.0000), TTF (1.0000), TCH (1.0000), FOC (1.0000), TTN (1.0000), KSD (1.0000), VMD (1.0000), TVC (1.0000), VEF (1.0000).
- Tệ nhất: VNR (0.0000), BSG (0.0000), DL1 (0.0000), VEA (0.0000), ITS (0.0000), VSF (0.0000), SBB (0.0000), SGT (0.0000), LIX (0.0000), MFS (0.0000).

## 3.6 K-nearest neighbors

Ta sử dụng mô hình KNN để phân loại đa lớp (3 nhãn: *down*, *sideways*, *up*), với số neighbors là 15 và dùng metric để chọn là khoảng cách euclidean.

### 3.6.1 TF-IDF vector

Kết quả: Accuracy = 0.4454

|              | Precision | Recall  | F1-Score | Support |
|--------------|-----------|---------|----------|---------|
| down         | 0.47934   | 0.50216 | 0.49049  | 924     |
| sideways     | 0.35294   | 0.06716 | 0.11285  | 268     |
| up           | 0.41606   | 0.50763 | 0.45731  | 786     |
| accuracy     |           |         | 0.44540  | 1978    |
| macro avg    | 0.41611   | 0.35899 | 0.35355  | 1978    |
| weighted avg | 0.43707   | 0.44540 | 0.42614  | 1978    |

Bảng 8: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: HHS (0.6000), PHP (0.5714), MSR (0.5583), SGT (0.5556), VSF (0.5556), CLX (0.4889), PVT (0.4821), RAL (0.4722), SAB (0.4571), DCM (0.4487).
- Tệ nhất: BSG (0.0000), DL1 (0.0000), VEA (0.0000), ITS (0.0000), SBB (0.0000), FIT (0.0000), KSD (0.0000), TTN (0.0000), FOC (0.0000), SAM (0.0000).



Hình 17: Dự đoán tốt nhất - HHS - Nguồn hình Fireant/TradingView



Hình 18: Dự đoán tệ nhất - SAM - Nguồn hình Fireant/TradingView

### 3.6.2 PhoBert

Kết quả: Accuracy = 0.4398

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| <b>down</b>         | 0.47390   | 0.49134 | 0.48247  | 924     |
| <b>sideways</b>     | 0.40323   | 0.09328 | 0.15152  | 268     |
| <b>up</b>           | 0.40814   | 0.49746 | 0.44839  | 786     |
| <b>accuracy</b>     |           |         | 0.43984  | 1978    |
| <b>macro avg</b>    | 0.42842   | 0.36069 | 0.36079  | 1978    |
| <b>weighted avg</b> | 0.43820   | 0.43984 | 0.42409  | 1978    |

Bảng 9: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: HT1 (0.6571), GDT (0.6250), SKG (0.6000), RAL (0.5714), SMB (0.5444), OIL (0.5079), PVT (0.4967), PTB (0.4889), CTR (0.4603), KSB (0.4444).
- Tệ nhất: BSG (0.0000), DL1 (0.0000), ITS (0.0000), SBB (0.0000), FIT (0.0000), KSD (0.0000), TTN (0.0000), SAM (0.0000), UNI (0.0000), VLB (0.0000).





Hình 19: Dự đoán tốt nhất - HT1 - Nguồn hình Fireant/TradingView



Hình 20: Dự đoán tệ nhất - UNI - Nguồn hình Fireant/TradingView

### 3.7 Decision tree

Ta sử dụng mô hình Decision tree để phân loại đa lớp (3 nhãn: *down*, *sideways*, *up*), với mục tiêu chọn lọc của cây là *gini*. Độ sâu tối đa của cây bằng 6 cho đến khi không chia được *min\_sample\_split* (trong thí nghiệm này là 2) nữa.

#### 3.7.1 TF-IDF vector

Kết quả: Accuracy = 0.4140

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| <b>down</b>         | 0.46456   | 0.39719 | 0.42824  | 924     |
| <b>sideways</b>     | 0.20382   | 0.11940 | 0.15059  | 268     |
| <b>up</b>           | 0.40719   | 0.53444 | 0.46222  | 784     |
| <b>accuracy</b>     |           |         | 0.41397  | 1976    |
| <b>macro avg</b>    | 0.35852   | 0.35034 | 0.34701  | 1976    |
| <b>weighted avg</b> | 0.40643   | 0.41397 | 0.40406  | 1976    |

Bảng 10: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: DVN (1.0000), DDG (1.0000), CST (1.0000), PLC (1.0000), VLB (1.0000), PSD (1.0000), UNI (1.0000), FOC (1.0000), MFS (1.0000), KSD (1.0000).
- Tệ nhất: PVI (0.0000), VNR (0.0000), BSG (0.0000), VEA (0.0000), TLG (0.0000), SBB (0.0000), TTN (0.0000), ABC (0.0000), VEC (0.0000), THD (0.0000).



Hình 21: Dự đoán tốt nhất - DVN - Nguồn hình Fireant/TradingView



Hình 22: Dự đoán tệ nhất - PVI - Nguồn hình Fireant/TradingView

### 3.7.2 PhoBert

Kết quả: Accuracy = 0.4155

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| <b>down</b>         | 0.46901   | 0.43398 | 0.45082  | 924     |
| <b>sideways</b>     | 0.24294   | 0.16045 | 0.19326  | 268     |
| <b>up</b>           | 0.39936   | 0.48087 | 0.43634  | 784     |
| <b>accuracy</b>     |           |         | 0.41549  | 1976    |
| <b>macro avg</b>    | 0.37044   | 0.35843 | 0.36014  | 1976    |
| <b>weighted avg</b> | 0.41071   | 0.41549 | 0.41014  | 1976    |

Bảng 11: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: CST (1.0000), PLC (1.0000), PSD (1.0000), KSD (1.0000), TVC (1.0000), VEF (1.0000), FOX (0.8730), IPA (0.8222), PGV (0.7778), KSB (0.7500).
- Tệ nhất: VNR (0.0000), BSG (0.0000), VNS (0.0000), ITS (0.0000), VSF (0.0000), SBB (0.0000), LIX (0.0000), TTN (0.0000), ABC (0.0000), FOC (0.0000).



Hình 23: Dự đoán tốt nhất - CST - Nguồn hình Fireant/TradingView



Hình 24: Dự đoán tệ nhất - VNS - Nguồn hình Fireant/TradingView

### 3.8 Random forest

Ta sử dụng mô hình Random forest để phân loại đa lớp (3 nhãn: *down*, *sideways*, *up*), với số cây là 200, và phương pháp phân chia cũng như decision tree ở trên là dùng chỉ số *gini* với chiều sâu tối đa mỗi cây là 6.

#### 3.8.1 TF-IDF vector

Kết quả: Accuracy = 0.4221

|              | Precision | Recall  | F1-Score | Support |
|--------------|-----------|---------|----------|---------|
| down         | 0.45786   | 0.39394 | 0.42350  | 924     |
| sideways     | 0.50000   | 0.11194 | 0.18293  | 268     |
| up           | 0.39251   | 0.56122 | 0.46194  | 784     |
| accuracy     |           |         | 0.42206  | 1976    |
| macro avg    | 0.45012   | 0.35570 | 0.35612  | 1976    |
| weighted avg | 0.43765   | 0.42206 | 0.40613  | 1976    |

Bảng 12: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: DDG (1.0000), CST (1.0000), PLC (1.0000), TCH (1.0000), UNI (1.0000), FOC (1.0000), KSD (1.0000), VMD (1.0000), TVC (1.0000), VEF (1.0000).
- Tệ nhất: BVH (0.0000), VNR (0.0000), BSG (0.0000), ITS (0.0000), SBB (0.0000), TTN (0.0000), ABC (0.0000), VEC (0.0000), VIF (0.0000), HHP (0.0000).



Hình 25: Dự đoán tốt nhất - FOC - Nguồn hình Fireant/TradingView



Hình 26: Dự đoán tệ nhất - TTN - Nguồn hình Fireant/TradingView

### 3.8.2 PhoBert

Kết quả: Accuracy = 0.4236

|              | Precision | Recall  | F1-Score | Support |
|--------------|-----------|---------|----------|---------|
| down         | 0.46030   | 0.40152 | 0.42890  | 924     |
| sideways     | 0.41176   | 0.10448 | 0.16667  | 268     |
| up           | 0.39746   | 0.55867 | 0.46448  | 784     |
| accuracy     |           |         | 0.42358  | 1976    |
| macro avg    | 0.42317   | 0.35489 | 0.35335  | 1976    |
| weighted avg | 0.42878   | 0.42358 | 0.40745  | 1976    |

Bảng 13: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: PLC (1.0000), UNI (1.0000), KSD (1.0000), VMD (1.0000), TVC (1.0000), VEF (1.0000), TTF (0.8000), HHS (0.7500), VSH (0.6875), PSD (0.6667).
- Tệ nhất: VNR (0.0000), BSG (0.0000), VEA (0.0000), ITS (0.0000), VSF (0.0000), SBB (0.0000), SGT (0.0000), TTN (0.0000), MFS (0.0000), ABC (0.0000).



Hình 27: Dự đoán tốt nhất - VMD - Nguồn hình Fireant/TradingView



Hình 28: Dự đoán tốt nhất - ITS - Nguồn hình Fireant/TradingView

### 3.9 AdaBoost

Ta sử dụng mô hình AdaBoost để phân loại đa lớp (3 nhãn: *down*, *sideways*, *up*). Thí nghiệm này AdaBoost có 200 vòng boosting với mỗi vòng dùng một decision tree với max depth là 1 và "learning rate=1"

#### 3.9.1 TF-IDF vector

Kết quả: Accuracy = 0.4231

|              | Precision | Recall  | F1-Score | Support |
|--------------|-----------|---------|----------|---------|
| down         | 0.46074   | 0.43182 | 0.44581  | 924     |
| sideways     | 0.35000   | 0.13060 | 0.19022  | 268     |
| up           | 0.39802   | 0.51276 | 0.44816  | 784     |
| accuracy     |           |         | 0.42308  | 1976    |
| macro avg    | 0.40292   | 0.35839 | 0.36140  | 1976    |
| weighted avg | 0.42084   | 0.42308 | 0.41208  | 1976    |

Bảng 14: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: DVN (1.0000), DDG (1.0000), CST (1.0000), PLC (1.0000), PSD (1.0000), UNI (1.0000), MFS (1.0000), VEF (1.0000), TTF (0.8000), CLX (0.7333).
- Tệ nhất: VNR (0.0000), BSG (0.0000), VEA (0.0000), TVC (0.0000), ITS (0.0000), VMD (0.0000), SBB (0.0000), SGT (0.0000), KSD (0.0000), TTN (0.0000).



Hình 29: Dự đoán tốt - CLX - Nguồn hình Fireant/TradingView





Hình 30: Dự đoán tệ nhất - SBB - Nguồn hình Fireant/TradingView

### 3.9.2 PhoBert

Kết quả: Accuracy = 0.4221

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| <b>down</b>         | 0.46614   | 0.44697 | 0.45635  | 924     |
| <b>sideways</b>     | 0.26506   | 0.08209 | 0.12536  | 268     |
| <b>up</b>           | 0.39623   | 0.50893 | 0.44556  | 784     |
| <b>accuracy</b>     |           |         | 0.42206  | 1976    |
| <b>macro avg</b>    | 0.37581   | 0.34600 | 0.34242  | 1976    |
| <b>weighted avg</b> | 0.41113   | 0.42206 | 0.40718  | 1976    |

Bảng 15: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: PLC (1.0000), PSD (1.0000), FOC (1.0000), SGT (1.0000), TVC (1.0000), VLB (0.7333), RAL (0.6500), MCH (0.6357), SAB (0.6071), VNG (0.5833).
- Tệ nhất: VNR (0.0000), SKG (0.0000), BSG (0.0000), ITS (0.0000), SBB (0.0000), LIX (0.0000), KSD (0.0000), TTN (0.0000), MFS (0.0000), ABC (0.0000).



Hình 31: Dự đoán tốt - MCH - Nguồn hình Fireant/TradingView



Hình 32: Dự đoán tệ nhất - MFS - Nguồn hình Fireant/TradingView

### 3.10 XGBoost

Ta sử dụng mô hình XGBoost để phân loại đa lớp (3 nhãn: *down*, *sideways*, *up*), với mục tiêu tối ưu là `multi:softprob` và đánh giá bằng log-loss đa lớp (`mlogloss`). Số cây được xây dựng là 200, độ sâu tối đa mỗi cây bằng 6, learning rate 0.1, kèm theo chiến lược lấy mẫu ngẫu nhiên 80% mẫu và 80% tính năng cho mỗi cây nhằm giảm overfitting.

#### 3.10.1 TF-IDF vector

Kết quả: Accuracy = 0.4322

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| <b>down</b>         | 0.47375   | 0.42965 | 0.45062  | 924     |
| <b>sideways</b>     | 0.31250   | 0.11194 | 0.16484  | 268     |
| <b>up</b>           | 0.40979   | 0.54464 | 0.46769  | 784     |
| <b>accuracy</b>     |           |         | 0.43219  | 1976    |
| <b>macro avg</b>    | 0.39868   | 0.36208 | 0.36105  | 1976    |
| <b>weighted avg</b> | 0.42650   | 0.43219 | 0.41863  | 1976    |

Bảng 16: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: DDG (1.0000), CST (1.0000), PLC (1.0000), SWC (1.0000), TCH (1.0000), VLB (1.0000), PSD (1.0000), UNI (1.0000), FOC (1.0000), KSD (1.0000).
- Tệ nhất: VNR (0.0000), BSG (0.0000), TLG (0.0000), ITS (0.0000), SBB (0.0000), TTN (0.0000), ABC (0.0000), VEC (0.0000), HT1 (0.0000), VIF (0.0000).



Hình 33: Dự đoán tốt nhất - UNI - Nguồn hình Fireant/TradingView



Hình 34: Dự đoán tệ nhất - HT1 - Nguồn hình Fireant/TradingView

### 3.10.2 PhoBert

Kết quả: Accuracy = 0.4367

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| <b>down</b>         | 0.48468   | 0.46212 | 0.47313  | 924     |
| <b>sideways</b>     | 0.29032   | 0.10075 | 0.14958  | 268     |
| <b>up</b>           | 0.40818   | 0.52168 | 0.45801  | 784     |
| <b>accuracy</b>     |           |         | 0.43674  | 1976    |
| <b>macro avg</b>    | 0.39439   | 0.36152 | 0.36024  | 1976    |
| <b>weighted avg</b> | 0.42797   | 0.43674 | 0.42325  | 1976    |

Bảng 17: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: PLC (1.0000), SWC (1.0000), PSD (1.0000), UNI (1.0000), KSD (1.0000), VMD (1.0000), TVC (1.0000), VEF (1.0000), VLB (0.7333), CLX (0.7333).
- Tệ nhất: VNR (0.0000), BSG (0.0000), VEA (0.0000), ITS (0.0000), VSF (0.0000), SBB (0.0000), TTN (0.0000), MFS (0.0000), ABC (0.0000), FOC (0.0000).



Hình 35: Dự đoán tốt nhất - PLC - Nguồn hình Fireant/TradingView



Hình 36: Dự đoán tệ nhất - TTN - Nguồn hình Fireant/TradingView

### 3.11 LightGBM

Ta sử dụng mô hình **LightGBM** để phân loại đa lớp (3 nhãn: *down*, *sideways*, *up*), với mục tiêu tối ưu là **multiclass** và đánh giá bằng log-loss đa lớp (**multi\_logloss**). Số cây được xây dựng là 200, độ sâu tối đa mỗi cây bằng 6, learning rate 0.1, kèm theo kiểu

#### 3.11.1 TF-IDF vector

Kết quả: Accuracy = 0.4261

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| <b>down</b>         | 0.45955   | 0.42424 | 0.44119  | 924     |
| <b>sideways</b>     | 0.33663   | 0.12687 | 0.18428  | 268     |
| <b>up</b>           | 0.40705   | 0.53061 | 0.46069  | 784     |
| <b>accuracy</b>     |           |         | 0.42611  | 1976    |
| <b>macro avg</b>    | 0.40108   | 0.36057 | 0.36205  | 1976    |
| <b>weighted avg</b> | 0.42205   | 0.42611 | 0.41408  | 1976    |

Bảng 18: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: IMP (0.6633), OIL (0.6556), DSN (0.6000), BIC (0.5778), ST8 (0.5556), PTB (0.4889), TDP (0.4889), IPA (0.4667), VSH (0.4469), SSI (0.4415).
- Tệ nhất: BSG (0.0000), DL1 (0.0000), VEA (0.0000), ITS (0.0000), VSF (0.0000), SBB (0.0000), LIX (0.0000), KSD (0.0000), TTN (0.0000), UNI (0.0000).



Hình 37: Dự đoán tốt nhất - IMP - Nguồn hình Fireant/TradingView



Hình 38: Dự đoán tệ nhất - LIX - Nguồn hình Fireant/TradingView

### 3.11.2 PhoBert

Kết quả: Accuracy = 0.4297

|                     | Precision | Recall  | F1-Score | Support |
|---------------------|-----------|---------|----------|---------|
| down                | 0.47646   | 0.44913 | 0.46240  | 924     |
| sideways            | 0.33696   | 0.11567 | 0.17222  | 268     |
| up                  | 0.39783   | 0.51403 | 0.44853  | 784     |
| <b>accuracy</b>     |           |         | 0.42966  | 1976    |
| <b>macro avg</b>    | 0.40375   | 0.35961 | 0.36105  | 1976    |
| <b>weighted avg</b> | 0.42634   | 0.42966 | 0.41754  | 1976    |

Bảng 19: Classification Report

Ngoài ra, ta cũng xếp hạng các mã cổ phiếu theo Weighted Average F1-Score mà mô hình này dự đoán tốt nhất cũng như tệ nhất:

- Tốt nhất: ST8 (0.6364), IPA (0.6111), HUT (0.5530), SMB (0.5444), VNG (0.5333), VGI (0.5333), PHP (0.5064), PGV (0.5000), OIL (0.5000), PVT (0.4571).
- Tệ nhất: BSG (0.0000), DL1 (0.0000), VEA (0.0000), ITS (0.0000), VSF (0.0000), SBB (0.0000), KSD (0.0000), TTN (0.0000), UNI (0.0000), HHP (0.0000).



Hình 39: Dự đoán tốt nhất - VNG - Nguồn hình Fireant/TradingView



Hình 40: Dự đoán tệ nhất - BSG - Nguồn hình Fireant/TradingView



### 3.12 Tổng hợp và nhận xét

|                                  | Precision      | Recall         | F1-Score       | Accuracy       |
|----------------------------------|----------------|----------------|----------------|----------------|
| Linear Regression - Baseline     | 0.44401        | 0.44365        | <b>0.44383</b> | 0.44365        |
| KNN - TFIDF                      | 0.43707        | <b>0.44540</b> | 0.42614        | <b>0.44540</b> |
| KNN - PhoBert                    | 0.43820        | 0.43984        | 0.42409        | 0.43984        |
| XGBoost - PhoBert                | 0.42797        | 0.43674        | 0.42325        | 0.43674        |
| Naive bayes - TFIDF              | <b>0.45556</b> | 0.43832        | 0.41873        | 0.43832        |
| XGBoost - TFIDF                  | 0.42650        | 0.43219        | 0.41863        | 0.43219        |
| LightGBM - PhoBert               | 0.42634        | 0.42966        | 0.41754        | 0.42966        |
| Support vector machine - TFIDF   | 0.43911        | 0.42864        | 0.41535        | 0.42864        |
| LightGBM - TFIDF                 | 0.42205        | 0.42611        | 0.41408        | 0.42611        |
| Support vector machine - PhoBert | 0.43880        | 0.42814        | 0.41265        | 0.42814        |
| AdaBoost - TFIDF                 | 0.42084        | 0.42308        | 0.41208        | 0.42308        |
| Decision tree - PhoBert          | 0.41071        | 0.41549        | 0.41014        | 0.41549        |
| Random forest - PhoBert          | 0.42878        | 0.42358        | 0.40745        | 0.42358        |
| AdaBoost - PhoBert               | 0.41113        | 0.42206        | 0.40718        | 0.42206        |
| Random forest - TFIDF            | 0.43765        | 0.42206        | 0.40613        | 0.42206        |
| Decision tree - TFIDF            | 0.40643        | 0.41397        | 0.40406        | 0.41397        |
| Naive bayes - PhoBert            | 0.41345        | 0.39585        | 0.40175        | 0.39585        |

Bảng 20: Bảng tổng hợp, sắp xếp theo Weighted avg F1-Score giảm dần.

Theo bảng số liệu, ta thấy phương pháp embedding sử dụng mô hình deep learning PhoBert không quá tốt hơn TFIDF khi áp dụng chung với các phương pháp machine learning truyền thống.

Do độ nhiễu mạnh của dữ liệu chứng khoán, có lẽ chỉ dữ liệu giá lịch sử và tin tức của cổ phiếu là chưa đủ để mô hình có thể dự đoán một cách tin cậy, hoặc cần ta mô hình machine learning mạnh mẽ hơn.

## 4 Kết luận

Qua quá trình nghiên cứu và triển khai hệ thống dự đoán xu hướng chứng khoán, nhóm đã có cơ hội tìm hiểu và ứng dụng nhiều thuật toán học máy khác nhau, từ các mô hình đơn giản như Linear Regression, Naive Bayes đến các mô hình phức tạp hơn như XGBoost và LightGBM.

Mặc dù kết quả của các mô hình còn nhiều hạn chế và cần được cải thiện thêm để đạt được độ chính xác cao hơn để có thể áp dụng trong thực tế, nhưng đề tài đã phần nào chứng minh được tiềm năng của việc ứng dụng học máy trong lĩnh vực tài chính. Trong tương lai, nhóm mong muốn có thể phát triển hệ thống theo hướng online, cập nhật dữ liệu theo thời gian thực, và tích hợp thêm các yếu tố phân tích kỹ thuật, phân tích vĩ mô cũng như vĩ mô để nâng cao chất lượng dự đoán.



## Tài liệu

- [1] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “Bert: Pre-training of deep bidirectional transformers for language understanding,” 2019.
- [2] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov, “Roberta: A robustly optimized bert pretraining approach,” 2019.
- [3] D. Q. Nguyen and A. T. Nguyen, “Phobert: Pre-trained language models for vietnamese,” 2020.